

115 年第一次・公告試題

第一科 逐題答案解析

完整保留公告試題的題幹與四個選項，再另外標出題目考點、各選項的判斷重點與易混淆概念。

原題完整保留

官方答案

A~D 逐項解析

原順序 / 主題排序

50

閱讀方式：50 題已全部直接展開。每題先列出原題與完整選項；「題目重點」及每個選項下方的「判斷重點」是另外加上的研讀標注，不會取代原文。

1

POS 詞性標註的目的

NLP · 原題第 1 題

答案 D

原始題目

某工程師正在建置一套法律文件解析系統，在進行資訊擷取（Information Extraction）前，需要對文本進行詞性標註（Part-of-Speech Tagging, POS Tagging）。請問此步驟的主要目的為何？

題目與選項標注

題目重點：法律文件進行資訊擷取前，使用 POS Tagging 的主要目的為何？

判斷關鍵：看到 POS / Part-of-Speech，就要想到「替每個詞標記語法角色」，不是切詞、翻譯或判斷情感。

A

將文本翻譯為其他語言以利跨語言分析；

判斷重點 | 錯誤：這是機器翻譯的任務，與詞性標註無關。

B

將文本切分為基本詞彙單位，以便後續處理；

判斷重點 | 錯誤：這是分詞（Tokenization）；分詞先決定詞的邊界，POS 再標記詞的語法類別。

C

判斷文本中各詞彙的情感傾向；

判斷重點 | 錯誤：這屬於情感分析，不是語法角色標註。

D

為每個詞彙標記其語法類別，如名詞、動詞與形容詞

判斷重點 | 正確：正確。POS 的功能就是為詞彙標記其詞性，並可支援 NER、關係抽取等後續任務。

原始題目

一家新創公司希望對 Llama3 70B 模型進行領域微調 (Domain Fine-Tuning) 以建立企業專用助理，但 GPU 記憶體有限，無法支撐完整模型的反向傳播梯度計算。工程師希望凍結 (freeze) 原模型權重、僅訓練少量額外參數的前提下，評估採用 LoRA (Low-RankAdaptation) 方案。請問 LoRA 在此場景下的主要優勢為何？

題目與選項標注

題目重點：GPU 記憶體有限，又希望凍結 70B 模型原始權重、只訓練少量額外參數，LoRA 的主要優勢是什麼？

判斷關鍵：題幹已給出「凍結原權重 + 少量額外參數」，正是 LoRA 以低秩矩陣進行參數高效微調的特徵。

A

透過知識蒸餾 (Knowledge Distillation) 將 70B 模型壓縮為較小的學生模型；

判斷重點 | 錯誤：這是知識蒸餾：讓小模型模仿大模型，不是 LoRA 的做法。

B

對原始模型各層權重進行剪枝 (Pruning)，移除低重要性參數後再進行微調；

判斷重點 | 錯誤：這是剪枝，會移除權重；LoRA 不需要刪除原模型參數。

C

凍結原始預訓練權重，僅在各層加入低秩分解的可訓練矩陣，大幅降低可訓練參數量與 GPU 記憶體需求；

判斷重點 | 正確：正確。只更新少量新增參數，可降低可訓練參數量、梯度與 GPU 記憶體需求。

D

將模型中的注意力機制改為稀疏注意力 (Sparse Attention)，以降低長序列計算成本

判斷重點 | 錯誤：稀疏注意力主要降低長序列注意力計算量，並非 LoRA 的核心。

原始題目

某工程師在建構搜尋引擎的詞向量模型時，語料庫規模達數十億 token，且包含大量長尾詞彙 (Long-tail Terms)。他在 Word2Vec 的 CBOW 與 Skip-gram 兩種訓練策略之間進行選擇，需考量訓練效率與低頻詞表示品質之差異。下列何者最能準確地反映兩者在此情境下的取捨？

題目與選項標注

題目重點：面對數十億 token 與大量長尾詞彙，CBOW 和 Skip-gram 在速度及低頻詞品質上如何取捨？

判斷關鍵：CBOW 是「周圍詞預測中心詞」，通常較快；Skip-gram 是「中心詞預測周圍詞」，對低頻詞較有利。

A CBOW 對長尾詞表現更好，因為它透過多個上下文詞的平均來強化稀疏詞的訓練訊號；

判斷重點 | 錯誤：方向顛倒；講義指出 Skip-gram 對低頻詞較有效。

B CBOW 訓練速度較快、整體語意平滑，但對低頻詞的向量品質較差；Skip-gram 以中心詞預測周圍詞，對長尾詞累積更多訓練樣本，向量品質較優；

判斷重點 | 正確：正確。這同時反映訓練效率與低頻詞表示品質的典型取捨。

C Skip-gram 訓練速度更快，因為每次只需預測單一目標詞，計算量低於 CBOW；

判斷重點 | 錯誤：通常相反；Skip-gram 需由一個中心詞預測多個上下文詞，計算量較高。

D 兩者對低頻詞的表現完全相同，差異僅在於訓練時的 Batch 組織方式

判斷重點 | 錯誤：錯誤。兩者的預測方向與對高 / 低頻詞的效果都有實質差異。

原始題目

某金融科技公司的工程師正在準備內部客服對話與交易紀錄文本，進行 BERT 模型的預訓練，以提升模型對金融語境的理解能力，並採用遮蔽語言建模（Masked Language Model, MLM）作為訓練任務。請問 MLM 的核心訓練目標為何？

題目與選項標注

題目重點：BERT 預訓練採用遮蔽語言模型（MLM）時，核心訓練目標為何？

判斷關鍵：MLM 是「遮住部分 token，再利用左右雙向上下文猜回原內容」。

A

讓模型自左至右逐 token 生成句子，學習自迴歸語言模型（Autoregressive LM）能力；

判斷重點 | 錯誤：這是自迴歸語言模型的方式，較接近 GPT，不是 BERT 的 MLM。

B

透過對抗訓練（Adversarial Training）縮小真實句與生成句之間的語意差異；

判斷重點 | 錯誤：這描述對抗式訓練，不是 MLM。

C

隨機遮蔽輸入序列中部分 token，訓練模型根據雙向上下文預測被遮蔽的原始內容；

判斷重點 | 正確：正確。BERT 同時利用遮蔽位置前後的資訊恢復原 token。

D

透過遮蔽低頻詞來減少詞彙表大小，降低 Embedding 的記憶體使用

判斷重點 | 錯誤：MLM 的目的不是壓縮 Embedding 或詞彙表，遮蔽也不限低頻詞。

原始題目

某電商平台的工程師在開發商品評論情感分析系統時，發現使用 One-Hot 編碼無法表達詞語之間的語意關係，且隨著詞彙表擴大，向量維度與記憶體需求快速增加。工程師因此改用 Word2Vec 進行詞語表示。請問 Word2Vec 從根本上解決了上述問題的哪項限制？

題目與選項標注

題目重點：One-Hot 維度高且不能表達詞義關係；改用 Word2Vec，根本改善了什麼？

判斷關鍵：One-Hot 是高維、稀疏、彼此孤立；Word2Vec 用低維稠密向量保存詞彙的語意關係。

A

建立詞語之間的序列依賴關係，以捕捉長距離上下文語意；

判斷重點 | 錯誤：Word2Vec 是靜態詞嵌入，不能處理長距離上下文或讓同一詞隨語境改變。

B

根據詞語在語料中的出現頻率調整其重要性，使模型更重視高頻詞；

判斷重點 | 錯誤：這較接近詞頻或 TF-IDF 的權重概念，不是 Word2Vec 的根本優勢。

C

降低詞彙表示的維度，同時保留語意結構，避免高維稀疏表示所帶來的限制；

判斷重點 | 正確：正確。分布式稠密向量同時改善高維稀疏與無法表達語意相似性的問題。

D

透過監督式學習利用標註語料，提升詞語分類的準確性

判斷重點 | 錯誤：Word2Vec 通常從未標註語料的上下文關係學習，不以詞語分類標籤為前提。

原始題目

某自駕車感知系統需要在同一張影像中同時完成道路、建築、行人的逐像素分類，並且能夠區分畫面中兩名相鄰行人（標記為「行人#1」和「行人#2」）。工程師在選擇語義分割（Semantic Segmentation）與實例分割（Instance Segmentation）時，請問兩者的根本差異為何？

題目與選項標注

題目重點：道路、建築、行人都要逐像素分類，且需區分兩名相鄰行人；兩種分割的根本差異為何？

判斷關鍵：兩者都有像素級分類；差別在「同一類別的不同個體是否分開」。

A

實例分割對每個像素進行分類但不產生 Bounding Box；語義分割產生 Bounding Box 但不進行像素級標記；

判斷重點 | 錯誤：兩者的核心都不是互換 Bounding Box；語義 / 實例分割都著重像素遮罩。

B

實例分割僅用於影像層級的類別分類，語義分割才進行逐像素標記；

判斷重點 | 錯誤：錯誤。實例分割同樣進行像素級遮罩，且還要區分個體。

C

語義分割將每個像素分配至預定義類別，但同一類別內的不同個體無法區分；實例分割能對同一類別的不同物件（如兩名行人）分別建立獨立遮罩（Mask）；

判斷重點 | 正確：正確。語義分割會把兩名行人都標成「行人」，實例分割則分成行人 #1、#2 的獨立遮罩。

D

語義分割與實例分割皆為逐像素分類任務，但兩者在是否需要區分不同物件個體上並無差異

判斷重點 | 錯誤：錯誤；是否區分同類別中的個別實例正是兩者主要差異。

原始題目

某大型超市的防損系統需要即時偵測多名顧客各自手持的購物籃、手機與商品，並需對每個物件進行精確區域標記（Pixel-level Mask），同時能區分畫面中不同個體（即使不同顧客拿著相同商品，也需分別標記）。請問下列哪一項技術最適合此場景的需求？

題目與選項標注

題目重點：超市防損系統要為每個購物籃、手機與商品做精確像素遮罩，並區分不同個體，應選哪項技術？

判斷關鍵：「Pixel-level Mask + 區分每一個物件」直接指向實例分割。

A 影像分類（Image Classification）；

判斷重點 | 錯誤：只判斷整張影像有哪些類別，不能定位每個物件。

B 目標檢測（Object Detection）；

判斷重點 | 錯誤：能用邊界框定位與分類，但不是精確到每個像素。

C 實例分割（Instance Segmentation）；

判斷重點 | 正確：正確。對每個物件建立獨立的像素級遮罩，符合全部需求。

D 語義分割（Semantic Segmentation）

判斷重點 | 錯誤：能逐像素分種類，但同一類別的多個商品或人物不會被分成不同實例。

原始題目

某工程師訓練了一個皮膚病變二元分類模型（惡性/良性），在向臨床醫師報告模型效能時，使用 ROC 曲線（Receiver Operating Characteristic Curve）進行呈現。請問 ROC 曲線的橫軸（X 軸）與縱軸（Y 軸）分別代表哪些指標，且在醫療情境中代表哪一種意義？

題目與選項標注

題目重點：二元醫療分類模型的 ROC 曲線，X 軸與 Y 軸各代表什麼？

判斷關鍵：ROC 固定記法：橫軸 FPR、縱軸 TPR；醫療上可理解為誤把健康者判陽性與正確找出病患。

A

X 軸為準確率（Accuracy），Y 軸為召回率（Recall），表示模型整體分類正確比例與偵測能力；

判斷重點 | 錯誤：ROC 不以 Accuracy 為橫軸。

B

X 軸為假陽率（False Positive Rate, FPR），Y 軸為真陽率（True Positive Rate, TPR），反映誤診健康個體的風險與正確識別病患的能力；

判斷重點 | 正確：正確。FPR 反映假警報 / 誤診健康者風險，TPR 就是 Recall / Sensitivity。

C

X 軸為精確率（Precision），Y 軸為召回率（Recall），表示預測為陽性樣本的準確性與完整性；

判斷重點 | 錯誤：這是 Precision–Recall 曲線的座標，不是 ROC。

D

X 軸為 IoU 閾值，Y 軸為 mAP，反映物件偵測模型在不同重疊條件下的表現

判斷重點 | 錯誤：IoU 與 mAP 用於物件偵測評估，與二元分類 ROC 不同。

原始題目

某團隊在監控影像分類模型的線上效能時，透過儀表板呈現混淆矩陣（Confusion Matrix），以觀察模型預測結果與實際標籤的分佈情形。請問下列哪一項無法從混淆矩陣中直接計算？

題目與選項標注

題目重點：只有一個分類門檻下的混淆矩陣，哪一項不能直接計算？

判斷關鍵：混淆矩陣提供 TP、FP、TN、FN，可算 Accuracy、Precision、Recall；AUC 需要掃描多個門檻形成整條 ROC。

A 精確率 (Precision)；

判斷重點 | 錯誤：可由 $TP / (TP + FP)$ 直接算出。

B 準確率 (Accuracy)；

判斷重點 | 錯誤：可由 $(TP + TN) / \text{全部樣本}$ 直接算出。

C 召回率 (Recall)；

判斷重點 | 錯誤：可由 $TP / (TP + FN)$ 直接算出。

D ROC 曲線下面積 (AUC)

判斷重點 | 正確：正確。單一門檻的混淆矩陣只是一個操作點，無法直接得到跨多門檻的曲線下面積。

原始題目

某工廠導入即時影像瑕疵偵測系統，需在高頻影像流中進行快速推論。工程師在 YOLO 與 Faster R-CNN 兩種物件偵測架構之間進行評估，請問下列哪一個針對兩者在偵測流程設計上的差異最為正確？

題目與選項標注

題目重點：高頻影像流需要快速推論；YOLO 與 Faster R-CNN 的偵測流程有何差異？

判斷關鍵：YOLO 是單階段；Faster R-CNN 是兩階段，先產生候選區域再分類與修正框。

A

YOLO 採用單階段偵測，直接從整張影像預測物件位置與類別；FasterR-CNN 則先產生候選區域再進行分類；

判斷重點 | 正確：正確。這也是 YOLO 通常較適合即時偵測的重要原因。

B

YOLO 與 Faster R-CNN 皆採用兩階段流程，但在特徵擷取方式上有所不同；

判斷重點 | 錯誤：YOLO 不先獨立產生候選區域，屬單階段偵測器。

C

YOLO 採用單階段架構，主要透過增加候選區域數量來提升偵測準確率；

判斷重點 | 錯誤：這不是 YOLO 的流程設計；候選區域是兩階段偵測器的重要概念。

D

Faster R-CNN 採用單階段偵測方式，將物件定位與分類整合於同一模型中

判斷重點 | 錯誤：方向顛倒；Faster R-CNN 由區域提議與後續分類 / 迴歸構成兩階段。

原始題目

某工程師在分析 Transformer 架構時，發現自注意力機制（Self-Attention）能夠有效提升模型對序列中長距離依賴關係的建模能力。請問 Self-Attention 的核心功能為何？

題目與選項標注

題目重點：Transformer 的自注意力為何能建模序列中的長距離依賴？

判斷關鍵：重點是每個 token 都能直接參照其他 token，並依關聯程度加權。

A

透過隱藏狀態的遞迴傳遞，逐步累積序列中的上下文資訊；

判斷重點 | 錯誤：這是 RNN 的序列處理方式，Transformer 不依賴逐步遞迴。

B

讓序列中每個 token 能與其他所有 token 建立關聯，並根據重要性分配權重；

判斷重點 | 正確：正確。可直接捕捉相隔很遠的詞彙關係。

C

對輸入序列進行局部運算，以捕捉相鄰詞之間的關係；

判斷重點 | 錯誤：這較像小型卷積核；Self-Attention 可檢視整段序列。

D

將整個序列壓縮為固定長度表示，以提供後續任務使用

判斷重點 | 錯誤：自注意力產生各位置的上下文表示，並非核心上先把整段壓成一個向量。

原始題目

某工程師在設計一個二元分類器 (BinaryClassifier) 時，考慮在輸出層使用 Sigmoid 函數。請問 Sigmoid 函數的主要特性與限制為何？

題目與選項標注

題目重點：二元分類輸出層使用 Sigmoid 時，主要特性與限制是什麼？

判斷關鍵： Sigmoid 輸出介於 0 與 1，可解讀為二元機率；兩端飽和時梯度接近 0。

A

可將輸入轉換為任意實數範圍，適合用於迴歸任務；

判斷重點 | 錯誤：線性輸出才可涵蓋任意實數；Sigmoid 被限制在 0~1。

B

可將輸入壓縮至(0, 1)區間，可解釋為機率值，但在輸入值過大或過小時可能產生梯度消失問題；

判斷重點 | 正確：正確。飽和區的導數很小，深層傳遞時會使學習困難。

C

可將輸入轉換為多類別機率分布，常用於多分類任務；

判斷重點 | 錯誤：多類互斥分類通常使用 Softmax；單一 Sigmoid 不會產生總和為 1 的多類分布。

D

可在整個輸入範圍內梯度保持穩定，適合用於深層神經網路

判斷重點 | 錯誤：恰好相反，輸入絕對值很大時容易飽和並造成梯度消失。

原始題目

某公司評估兩種方案，將大型語言模型客製化為內部客服助理：方案 A 為提示微調 (PromptTuning)，在輸入端加入可學習的軟提示 (SoftPrompt)；方案 B 為傳統微調 (Fine-Tuning)，以標註問答資料調整模型。兩方案最本質的技術差異為何？

題目與選項標注

題目重點：軟提示微調與傳統微調，最本質的技術差異為何？

判斷關鍵： Prompt Tuning 主要學習輸入端的 Soft Prompt；傳統微調則更新模型本身的部分或全部權重。

A

提示微調主要用於降低推論延遲，而傳統微調則用於提升模型容量；

判斷重點 | 錯誤：兩者主要差別是哪些參數被訓練，不是各自專門解決延遲或容量。

B

兩者技術本質相同，差別僅在於學習率 (Learning Rate) 設定不同；

判斷重點 | 錯誤：可訓練參數的位置與數量不同，不只是超參數不同。

C

傳統微調通常需要更新模型參數，而提示微調主要透過調整輸入表示來影響模型行為；

判斷重點 | 正確：正確。Soft Prompt 是輸入端可學習向量，通常可凍結底層模型。

D

提示微調與傳統微調的差異僅在於是否使用預訓練模型

判斷重點 | 錯誤：兩者通常都建立在預訓練模型之上。

原始題目

某工程師計劃將通用 LLM 在醫療問答語料上進行監督微調 (Supervised Fine-Tuning, SFT)，但發生了災難性遺忘 (Catastrophic Forgetting) 問題。在計算資源有限的情況下，工程師希望透過調整微調策略來緩解此問題。下列哪一種訓練設計最能有效率地學習新任務的同時保留原有能力？

題目與選項標注

題目重點：計算資源有限時，醫療 SFT 如何有效學新任務又盡量保留通用模型原能力？

判斷關鍵：限制更新範圍可減少新任務梯度對原有權重的全面覆寫；LoRA 是典型參數高效策略。

A

凍結大部分預訓練參數，僅對少量新增模組（如 LoRA 層）進行微調，並控制更新範圍以減少對原有知識的干擾；

判斷重點 | 正確：正確。能降低資源需求，也減少對原有知識表示的干擾。

B

提高學習率 (LearningRate) 並縮短訓練步數，使模型快速收斂至新任務，避免長時間訓練造成遺忘；

判斷重點 | 錯誤：高學習率可能造成更劇烈的權重更新，反而加重遺忘。

C

僅使用醫療語料進行多輪訓練，強化模型對新任務的專注程度；

判斷重點 | 錯誤：缺少原任務或通用資料約束，容易讓模型更偏向新領域並遺忘舊能力。

D

增加批次大小 (Batch Size) 以穩定梯度更新，使模型同時保留舊知識與學習新知識

判斷重點 | 錯誤：可改變梯度穩定性，但不能直接保證保留既有知識。

原始題目

某企業建置一套多代理人（Multi-Agent）系統，由一個 OrchestratorAgent 負責任務分配，多個 Worker Agent 分別執行網路搜尋、程式撰寫與結果彙整。若 Orchestrator 發現某 Worker Agent 回傳結果品質不符合預期，從系統容錯與任務可靠性角度，下列哪一項機制最能確保整體任務仍能正確完成？

題目與選項標注

題目重點：Orchestrator 發現 Worker 結果不合格時，怎麼確保整體任務仍能完成？

判斷關鍵：可靠性來自「評估結果→失敗處理→重試或改派→留下紀錄」，而不是忽略錯誤或整體中止。

A 直接採用該 Worker Agent 的輸出，避免重試機制造成延遲；

判斷重點 | 錯誤：會把已知錯誤傳到最終結果，違反品質控管。

B Orchestrator 具備結果評估能力，對不合格結果觸發重試（Retry）或重新分配給不同 Worker，並記錄失敗原因供後續改善；

判斷重點 | 正確：正確。這是任務層級容錯、重試與可觀測性的完整做法。

C 強制所有 Worker Agent 統一使用相同的 LLM 模型，以減少輸出差異；

判斷重點 | 錯誤：一致模型不保證結果正確，也會降低備援多樣性；關鍵是驗證與重試。

D 當任何一個 Worker 失敗時，整個 Multi-Agent 任務直接中止並通知使用者重新啟動

判斷重點 | 錯誤：失去多代理系統可重新分派與局部復原的價值。

原始題目

一位工程師正在實作一個 ReAct 框架的 AI Agent，該 Agent 需要回答「台灣目前最大的電動車充電站營運商是哪間公司，以及其充電樁總數」。Agent 的工具清單如下：

- web_search(query)：回傳搜尋結果摘要
 - get_webpage(url)：回傳網頁內文
 - calculator(expression)：回傳計算結果
 - get_current_date()：回傳今日日期
- 工程師設計了以下的 System Prompt 與 ReAct Loop，請問此 Agent 設計存在哪些問題？應如何改善？[System Prompt] 你是一個資料查詢助理。每次只能使用一個工具。當你知道答案時，直接輸出最終答案。[第一輪 Agent 輸出] Thought: 我已經知道台灣電動車市場的概況，不需要搜尋，可以直接回答。Action: 無 Answer: 台灣最大充電站營運商是 XX 公司，共有 500 個充電樁。

題目與選項標注

題目重點：Agent 面對「目前最大營運商與充電樁總數」卻未搜尋就直接回答，設計問題是什麼？

判斷關鍵：「目前」代表資訊會變動。系統提示應要求先使用工具查證，否則模型可能用過時知識或直接幻覺。

A

System Prompt 未要求 Agent 在回答前使用工具驗證，導致直接依賴既有知識產生幻覺（Hallucination）；應明確規定即時性問題需先執行 web_search；

判斷重點 | 正確：正確。工具存在但 Prompt 沒規定何時必須使用，Agent 因而跳過查證並生成未證實答案。

B

工具清單提供了 calculator 與 get_current_date，屬於多餘工具，可能增加 Agent 的選擇複雜度；

判斷重點 | 錯誤：工具是否多餘不是本次錯答的主因；核心缺陷是缺少查證規則。

C

ReAct 框架的核心問題在於 Thought 步驟佔用過多 token，應移除 Thought 欄位，直接讓 Agent 輸出 Action，以提升推理效率；

判斷重點 | 錯誤：ReAct 的重點正是交替推理與行動；移除推理步驟不能解決未查證問題。

D

Agent 應在第一輪就呼叫所有可用工具並彙整結果，避免多輪 Loop 造成的延遲

判斷重點 | 錯誤：應按任務需要逐步使用相關工具，不必呼叫無關工具，也不符合每次一個工具的設計。

原始題目

某醫療新創公司正在開發一套「多模態患者風險評估系統」，需同時處理三種異質資料來源：胸腔 X 光影像（影像模態）、臨床診斷筆記（文字模態），以及心率與血氧的時序感測資料（數值時序模態）。工程師在進行各模態的特徵擷取模型選擇時，需為每種模態挑選最適合的模型架構。下列哪一組模型配置最符合三種模態各自的資料特性？

題目與選項標注

題目重點：X 光影像、臨床文字、心率血氧時序資料，最合理的模型配置是什麼？

判斷關鍵：先看資料結構：影像重空間局部特徵、文字重語境、時序重時間依賴。

A 影像模態用 LSTM、文字模態用 CNN、時序模態用 BERT；

判斷重點 | 錯誤：三種架構與主要資料特性大多錯配。

B 影像模態用 TF-IDF、文字模態用 ResNet、時序模態用 Word2Vec；

判斷重點 | 錯誤：TF-IDF / Word2Vec 是文字表示，ResNet 是影像 CNN，配置錯位。

C 三種模態統一使用 BERT，因為 Transformer 架構具備通用性，可處理任意形式的輸入資料；

判斷重點 | 錯誤：Transformer 可延伸至多模態，但原始影像與連續感測資料仍需合適的輸入表示或專用編碼器，不能因通用性就直接套用文字 BERT。

D 影像模態用 CNN、文字模態用 Transformer、時序模態用 LSTM 或 Temporal CNN

判斷重點 | 正確：正確。各自對應影像空間、文字語境與時間序列特性。

原始題目

某醫院的 AI 研究團隊正在開發一套整合「CT 影像+電子病歷文本+基因序列」三種模態資料的癌症預測模型。請問在此場景中採用「跨模態對齊（Cross-Modal Alignment）」技術主要解決什麼問題？

題目與選項標注

題目重點：CT、電子病歷與基因序列一起建模時，Cross-Modal Alignment 主要解決什麼？

判斷關鍵：對齊的核心不是刪除某模態或降低成本，而是把不同模態放進可互相比較與關聯的共同語意空間。

A

使模型僅聚焦於 CT 影像資料，避免文本與基因資料引入雜訊；

判斷重點 | 錯誤：這違反多模態整合目的。

B

自動生成跨模態配對標註，以減少人工標記需求；

判斷重點 | 錯誤：對齊通常需要利用配對或關聯資料學習，但主要目的不是自動標註。

C

降低多模態資料的儲存與計算成本，以提升訓練效率；

判斷重點 | 錯誤：可能有其他壓縮方法處理成本；跨模態對齊首先處理的是語意關聯。

D

將不同模態的資料表示對齊至共同語意空間，使模型能建立跨模態之間的語意關聯

判斷重點 | 正確：正確。模型才能理解影像、文字與基因表示之間的對應關係。

原始題目

一家電商公司已將推薦系統 AI 模型上線三個月，業務主管要求專案團隊評估導入成效。團隊根據下圖數據得出結論：「因為 AUC 高達 0.91，模型表現優異，AI 導入成效良好。」請問此評估結論存在什麼根本問題？

指標	導入前	導入後
模型離線 AUC	—	0.91
點擊率 (CTR)	3.2%	3.1%
平均訂單金額	\$850	\$1,020
系統推論延遲	—	平均 85ms
模型推論費用	—	每月 \$12,000

題目與選項標注

題目重點：推薦模型 AUC 0.91，但 CTR 略降、平均訂單金額上升；只說「AUC 高所以導入成功」有何問題？

判斷關鍵：模型指標回答「模型算得好不好」；導入成效還要回答「真實業務是否改善」，必須一起看線上指標。

A

僅依賴離線指標 AUC 判斷模型成效，忽略線上業務指標（如 CTR 與營收）的變化，可能導致錯誤結論；

判斷重點 | 正確：正確。單一離線指標不能代表真實使用者行為與商業效益。

B

AUC 已達 0.91，代表模型排序能力優異，即使 CTR 略為下降，仍可視為推薦品質提升；

判斷重點 | 錯誤：排序能力改善不等於線上體驗或轉換改善，不能忽略業務指標。

C

CTR 從 3.2%降至 3.1%，顯示模型效果變差，應立即還原（Rollback）至舊模型；

判斷重點 | 錯誤：也過度武斷；應綜合統計顯著性、營收、訂單金額與其他指標判斷。

D

平均訂單金額提升至\$1,020，代表模型已成功優化營收，因此無需考慮其他指標

判斷重點 | 錯誤：同樣只看單一指標，無法排除流量、轉換或其他因素。

原始題目

某電商公司計畫導入即時推薦系統，希望使用者進入網站後能在 100 毫秒內取得推薦結果，且推薦結果需依據最新使用者行為進行調整。系統需支援每日約 50 萬活躍使用者，尖峰時段每秒約 3,000 筆請求 (QPS)。目前公司已累積歷史購買紀錄與瀏覽行為資料，並持續接收即時點擊流 (Streaming Data)。IT 基礎架構採用雲端環境，團隊配置為 2 名資料工程師與 1 名機器學習工程師。某工程師提出以下導入規劃：(1)使用批次訓練 (Batch Training) 建立協同過濾模型 (2)將模型部署為 REST API 提供即時推論服務 (3)使用 Kafka 串流處理即時使用者行為特徵 (4)將所有即時資料先寫入資料倉儲 (Data Warehouse) 再進行特徵計算 (5)使用 Redis 或 Feature Store 快取即時特徵請問以下哪一項最合理的技術導入規劃組合與調整建議？

題目與選項標注

題目重點：100ms 即時推薦要利用最新點擊流；批次訓練、REST API、Kafka、資料倉儲與 Feature Store 應如何取捨？

判斷關鍵：資料倉儲適合分析，不宜放在毫秒級即時特徵的熱路徑；串流 + 低延遲特徵存取才符合需求。

A

保留(1)(2)(3)，移除(4)，並加入(5)以降低延遲；

判斷重點 | 正確：正確。離線模型可搭配即時行為特徵，避免資料倉儲增加線上延遲。

B

保留(1)(4)，移除(3)，以確保資料一致性與系統穩定；

判斷重點 | 錯誤：無法及時納入最新點擊流，也難滿足 100ms。

C

保留(2)(4)(5)，移除(1)，改用即時線上學習 (Online Learning)；

判斷重點 | 錯誤：需求只說結果需依最新行為調整，不代表一定要即時更新模型權重；且仍保留資料倉儲熱路徑。

D

全部保留(1)~(5)，可同時兼顧即時性與資料完整性

判斷重點 | 錯誤：把所有即時資料先寫入倉儲再算特徵，會成為不必要的延遲瓶頸。

原始題目

一位機器學習工程師正在優化公司內部的 RAG 法律文件問答系統。近期因營運成本壓力，公司要求在不更換模型且不影響回答品質的前提下，將整體 token 成本降低至目前的 60%，且目前成本主要集中於輸入 tokens。工程師在檢查系統後，盤點出目前的使用情況如下：◆使用模型：GPT-4o（輸入 \$5 / 1M tokens、輸出 \$15 / 1M tokens）◆每次查詢：將前 10 筆檢索文件區塊全部加入 Prompt（每塊約 600 tokens）◆System Prompt：每次請求均包含約 500tokens 的公司背景說明◆對話機制：保留完整對話歷史，平均累積約 8,000tokens◆每日查詢量：約 5,000 次◆平均輸出：約 300tokens / 次在上述限制與系統現況下，請問下列哪一項優化組合，最能在維持回答品質的前提下有效降低 token 成本？

題目與選項標注

題目重點：成本主要來自輸入 tokens；在不換模型、不影響回答品質下，哪個組合最有效？

判斷關鍵：先處理最大的輸入來源：每次重複的 500-token 系統前綴，以及平均 8,000-token 的完整對話歷史。

A 將輸出 max_tokens 從 1,000 壓縮至 200，強制模型給出更短的回答，以降低輸出費用；

判斷重點 | 錯誤：成本主因是輸入，且硬砍輸出可能截斷必要的法律回答並傷害品質。

B 將 System Prompt 改為 Prompt Caching 或靜態前綴重用，並對對話歷史實作摘要壓縮，以保留語意而非完整對話；

判斷重點 | 正確：正確。直接針對大量重複輸入與歷史內容，保留語意同時降低輸入量。

C 將所有查詢改為 Batch API 模式送出，透過非同步處理降低單次費用；

判斷重點 | 錯誤：互動式問答通常需要即時回應；批次處理也不會減少輸入 token 數量。

D 在 Prompt 中明確要求模型「回答時盡量簡短」，透過指令引導模型自行縮減輸出長度

判斷重點 | 錯誤：主要縮減輸出，而題幹指出成本集中於輸入，效果有限。

原始題目

某金融科技公司計劃建立完整的 AI 開發到維運流程，希望實現「模型訓練→測試→部署→監控→再訓練」的自動化流程串接，並確保線上模型的版本可追溯。技術主管建議引入 MLOps 框架。MLOps 在此 AI 開發生命週期中的核心角色為何？

題目與選項標注

題目重點：要串接訓練、測試、部署、監控、再訓練，並讓線上模型版本可追溯，MLOps 的核心角色是什麼？

判斷關鍵：題幹列出的就是完整 ML 生命週期；答案要同時涵蓋流程自動化、版本、部署、監控與更新。

A 專注於訓練資料的標註與品質控管，以提升模型訓練效果；

判斷重點 | 錯誤：資料品質重要，但只是生命週期的一部分。

B 透過自動化模型搜尋與參數調整，降低模型開發門檻；

判斷重點 | 錯誤：這是 AutoML / 超參數最佳化範圍，未涵蓋部署與監控。

C 建立機器學習流程的自動化與版本管理機制，支援模型部署、監控與持續更新；

判斷重點 | 正確：正確。完整對應題幹所需的端到端治理與可追溯性。

D 確保模型在部署後維持穩定效能，減少後續維運與更新需求

判斷重點 | 錯誤：MLOps 恰恰包含持續監控、漂移偵測與更新，不能消除後續工作。

原始題目

某製造業公司計劃將 AI 導入生產線瑕疵檢測流程，目前瑕疵樣本約 800 張（含各類瑕疵類型）、正常樣本約 15,000 張，現有 IT 基礎設施為地端伺服器且無 GPU，且生產線環境需於地端即時完成推論，檢測需求為每片零件須在 100 毫秒內完成檢測，且預算為中等、無法於短期內大規模採購硬體。工程師正在規劃第一階段的 AI 導入方案，請問下列哪一種規劃最為合適？

題目與選項標注

題目重點：瑕疵 800 張、正常 15,000 張，地端無 GPU、100ms 延遲、中等預算，第一階段怎麼規劃？

判斷關鍵：限制同時包含資料少、硬體弱、必須地端低延遲；答案要一次處理三項限制。

A

從零訓練一個大型 CNN 模型，並採購高階 GPU 伺服器以滿足推論速度需求；

判斷重點 | 錯誤：資料量與預算都不適合，也違反短期硬體限制。

B

採用預訓練模型進行 Transfer Learning，針對瑕疵樣本進行 Fine-tuning，並使用模型量化（Quantization）或蒸餾（Distillation）技術壓縮模型以符合延遲需求，部署於地端；

判斷重點 | 正確：正確。遷移學習因應小資料，模型壓縮因應延遲與硬體，地端部署符合環境限制。

C

因樣本數不足，建議先暫緩 AI 導入，待蒐集至少 10 萬筆瑕疵樣本後再啟動專案；

判斷重點 | 錯誤：門檻武斷；可透過遷移學習、資料增強與不平衡處理先驗證。

D

將所有影像上傳至雲端，使用第三方 AutoML 平台自動訓練並部署，以節省開發時間

判斷重點 | 錯誤：生產線要求地端即時推論，網路與雲端路徑不符合限制。

原始題目

某即時詐欺偵測系統對模型回應時間有嚴格限制，若推論延遲過高將影響交易核准流程。維運工程師在模型上線前進行延遲測試（Latency Testing）時，主要評估的目標為何？

題目與選項標注

題目重點：即時詐欺偵測在上線前做延遲測試，主要評估目標為何？

判斷關鍵： Latency 就是一次請求從輸入到輸出的耗時；不要和資源、資安、公平性測試混淆。

A

評估模型推論過程中的記憶體使用量，以確認部署資源是否足夠；

判斷重點 | 錯誤：這是資源 / 容量測試的重要指標，但不是延遲本身。

B

驗證模型對異常或攻擊輸入的穩定性與安全性；

判斷重點 | 錯誤：這屬魯棒性與安全測試。

C

評估模型在不同使用者族群上的預測結果是否一致；

判斷重點 | 錯誤：這屬公平性評估。

D

評估模型從接收輸入到產生預測結果所需的回應時間是否符合系統要求

判斷重點 | 正確：正確。應進一步關注平均值與 P95 / P99 等尾端延遲。

原始題目

某企業欲將其 AI 輔助決策系統提交給外部稽核單位審查，並宣稱符合 NIST 《AI 風險管理框架》（NIST AI RMF）中可驗證性（Verifiability）的要求。為讓第三方稽核人員能獨立重現模型評估結果，下列哪一項技術實踐最直接符合此要求？

題目與選項標注

題目重點：NIST AI RMF 的可驗證性要求第三方能獨立重現評估結果，最直接的實踐是什麼？

判斷關鍵：「第三方重現」需要資料、流程、版本與關鍵設定可追溯，而不是只追求高準確率。

A

將模型測試準確率優化至 99% 以上，以達到業界公認的高可靠標準；

判斷重點 | 錯誤：高準確率不代表別人能重現，也不是所有任務的通用門檻。

B

建立可追溯的測試資料與評估流程，並記錄模型訓練與評估過程中的關鍵設定，以確保結果可被重現；

判斷重點 | 正確：正確。具備資料版本、程式 / 模型版本、參數與評估紀錄，第三方才能重做並比較結果。

C

加快模型迭代速度，縮短版本發布週期以盡快累積外部驗證數據；

判斷重點 | 錯誤：速度不等於可驗證性，反而更需要嚴謹版本紀錄。

D

擴充訓練資料量至數百萬筆，以統計方式確保模型的泛化能力達標

判斷重點 | 錯誤：資料量可能改善泛化，但不能取代可追溯與可重現流程。

原始題目

某銀行導入一套 AI 授信審核系統，針對貸款申請人進行自動化決策。監理單位要求系統必須符合負責任 AI（ResponsibleAI）原則，特別是對被拒絕的申請人提供每筆決策的具體理由說明。從技術與合規的角度，此要求的核心能力需求為何？

題目與選項標注

題目重點：銀行自動授信被拒時，監理要求對每一筆決策提供具體理由，核心能力是什麼？

判斷關鍵：題目要求的是「為什麼拒絕」，因此要能說明哪些特徵如何影響該次決策。

A

系統必須在收到申請後 10 秒內自動刪除申請人個資；

判斷重點 | 錯誤：這是資料保存與隱私議題，不能提供決策理由。

B

系統應隨機調整部分決策以確保多元性；

判斷重點 | 錯誤：隨機化會降低一致性與公平性，並不產生可理解的理由。

C

系統必須保證所有決策準確率達到 100%；

判斷重點 | 錯誤：實務上不合理，而且準確率高也不代表決策可解釋。

D

系統必須具備可解釋性（Explainability）能力，能提供特徵貢獻說明

判斷重點 | 正確：正確。可針對單一申請說明收入、負債等特徵如何推動模型輸出。

原始題目

某醫院計劃導入一套 AI 醫療影像診斷輔助系統，用於輔助放射科醫師判讀 CT 影像。院方技術委員會討論在人命攸關且需確保最終臨床決策責任由人類承擔的情境下，從系統設計架構層面，最關鍵的安全機制為何？

題目與選項標注

題目重點：醫療影像診斷攸關人命，且最終臨床責任必須由人類承擔，最關鍵的安全機制是什麼？

判斷關鍵：看到「最終責任由人類承擔」，答案就是讓醫師位於決策迴路中並做最後審核。

A

採用人機協作（Human-in-the-Loop, HITL）架構，由醫師最終審核決策；

判斷重點 | 正確：正確。AI 提供輔助判讀，但人類保有覆核與最終決策權。

B

模型信心低於閾值（Threshold）即自動關機；

判斷重點 | 錯誤：可設計轉人工或拒答，但直接關機不是完整的臨床安全與責任機制。

C

隨機切換模型並以多數決決策；

判斷重點 | 錯誤：模型集成可能改善穩定性，但不能取代醫師最終責任。

D

對輸入影像加入隨機擾動

判斷重點 | 錯誤：這是資料增強或魯棒性測試概念，不是臨床決策治理。

原始題目

一位資料科學家使用 XGBoost 建立信用風險評分模型，並使用 SHAP 解釋模型對某申請人的預測結果。SHAPsummaryplot 顯示該樣本中「月收入」的 SHAP 值為-2.3，「負債比率」為+1.8，其中 SHAP 值代表各特徵對模型輸出值的影響程度與方向。關於對 SHAP 值的解讀，下列敘述何者正確？

題目與選項標注

題目重點：某申請人的「月收入」SHAP=-2.3、「負債比率」SHAP=+1.8，應如何解讀？

判斷關鍵：SHAP 表示相對於 base value，某特徵把這一筆模型輸出往正或負方向推多少；單位依模型輸出尺度而定。

A

「月收入」的SHAP值-2.3代表該特徵使此申請人的違約預測機率降低了2.3%；

判斷重點 | 錯誤：SHAP 值不必然直接等於百分點；可能是在 log-odds 或其他模型輸出尺度上。

B

「月收入」的 SHAP 值-2.3 代表相對於基準值（basevalue），此特徵將模型輸出值往負方向推移了 2.3 個單位，表示月收入對該申請人有降低違約風險的貢獻；

判斷重點 | 正確：正確。負號表示該特徵對此樣本的預測方向為降低模型輸出。

C

SHAP 值為負代表該特徵對模型整體來說是不重要的特徵，應考慮從模型中移除；

判斷重點 | 錯誤：正負表示影響方向，重要性要看絕對值大小；負值不等於不重要。

D

「負債比率」SHAP 值+1.8 代表負債比率是整個訓練集中對違約影響最大的特徵

判斷重點 | 錯誤：這只是該樣本的局部貢獻，不能據此判定全體資料的全域重要性。

原始題目

某工程師為一套卷積神經網路（CNN）的醫療影像輔助診斷系統設計模型可解釋性機制。該系統需滿足下列需求：1.能向醫師說明影像被判定為異常的原因 2.支援近即時推論，每次解釋須於 200 毫秒內完成，且不可進行大量重複採樣計算 3.解釋結果須以影像中具代表性的視覺化像素區域呈現在此情境下，下列何種方法最為適合？

題目與選項標注

題目重點：CNN 醫療影像需要 200ms 內產生代表性像素區域，且不能大量重複採樣，應選哪種方法？

判斷關鍵：限制條件是 CNN、視覺熱區、低延遲、不要大量採樣；Grad-CAM 可用梯度直接產生類別關注圖。

A

使用 LIME，透過超像素擾動取樣分析影像區塊對預測的影響；

判斷重點 | 錯誤：需要建立多個擾動樣本並反覆推論，較難滿足嚴格低延遲。

B

使用 SHAP KernelExplainer，計算各像素的 Shapley 值並疊加於原始影像；

判斷重點 | 錯誤：模型無關但計算昂貴，也依賴大量採樣近似。

C

使用 Grad-CAM (Class Activation Map)，透過梯度反向傳播生成類別關注區域；

判斷重點 | 正確：正確。適合 CNN，可快速產生影像熱力圖，符合近即時與視覺區域需求。

D

使用 SHAP TreeExplainer，計算特徵貢獻並以熱力圖呈現

判斷重點 | 錯誤：專為樹模型最佳化，不適用 CNN 的卷積特徵圖。

原始題目

某資料科學家正在處理一份包含 200 個感測器特徵的工廠設備監測資料集，為了降低模型複雜度並保留主要變異資訊，他先對資料進行標準化（Standardization），再使用主成分分析（PCA）進行降維。在 PCA 過程中，為了找出能最大化資料變異量的主成分方向，演算法主要依賴哪一項數學操作？

題目與選項標注

題目重點：標準化後使用 PCA，如何找出最大化資料變異量的主成分方向？

判斷關鍵：PCA 的主成分是協方差矩陣最大特徵值所對應的特徵向量；也可由 SVD 求得。

A

透過對目標函數進行梯度下降（GradientDescent）最佳化，迭代求得主成分方向；

判斷重點 | 錯誤：PCA 經典解法不是依賴梯度下降，而是特徵值分解或 SVD。

B

根據特徵與目標變數之間的相關性（Correlation）進行排序，選擇重要特徵；

判斷重點 | 錯誤：PCA 是非監督式降維，不使用目標變數。

C

對資料的協方差矩陣（Covariance Matrix）進行特徵值分解（Eigen Decomposition），取得對應主要變異方向的特徵向量；

判斷重點 | 正確：正確。特徵向量給出主成分方向，特徵值代表該方向解釋的變異量。

D

對資料矩陣進行卷積運算（Convolution），擷取特徵之間的局部關係

判斷重點 | 錯誤：卷積擷取局部模式，不是 PCA 的線性代數核心。

原始題目

某資料工程師嘗試對包含 300 個特徵的使用者行為資料集使用 DBSCAN 進行群集分析，但發現幾乎所有資料點都被判定為雜訊點（Noise Points），難以形成有意義的群集，即使不斷調整 ϵ （Epsilon）與 MinPts 參數也無濟於事。請問下列何者為此問題最可能的根本原因？

題目與選項標注

題目重點：300 維資料用 DBSCAN，幾乎所有點都成為雜訊且調 ϵ 、MinPts 無效，最可能原因是什麼？

判斷關鍵：DBSCAN 依賴距離與局部密度；高維時距離差異變小，鄰域密度難以區分。

A

在高維空間中，維度詛咒（Curse of Dimensionality）使得資料點之間的距離趨於相近，導致 DBSCAN 的密度估計失效；

判斷重點 | 正確：正確。高維空間的距離集中現象會讓 ϵ 鄰域難以設定。

B

DBSCAN 演算法僅適用於低維資料，無法處理高維資料；

判斷重點 | 錯誤：說法過度絕對；可先降維、選特徵或更換距離度量後再使用。

C

300 個特徵的資料必然不具備群集結構，因此無法進行有效的分群；

判斷重點 | 錯誤：高維不代表資料一定沒有群集，只是以原始距離估計變困難。

D

高維空間中核心點的數量會受到數學限制，導致無法形成群集

判斷重點 | 錯誤：沒有這種普遍固定限制；根本問題是高維距離與密度判斷失真。

原始題目

某工程師正在實作一個 CNN 影像分類模型，在 PyTorch 中定義模型架構時，需要在卷積擷取特徵後接上全連結層（FullyConnectedLayer）進行分類。在模型程式碼中，需要在卷積輸出與全連結層之間插入什麼操作？

題目與選項標注

題目重點：PyTorch CNN 在卷積特徵圖與 Fully Connected Layer 之間，需要插入什麼操作？

判斷關鍵：全連結層接收二維的「批次×特徵」張量；一般做法是先把通道、高、寬展平成一維特徵。

A 使用全域平均池化（GlobalAverage Pooling）將特徵圖壓縮後再接全連結層；

判斷重點 | 錯誤：GAP 是可選的替代設計，可把每個通道壓成一值，但不是題目所問的通用必要操作。

B 使用 Flatten 將特徵圖展平成一維向量；

判斷重點 | 正確：正確。將卷積輸出的多維特徵圖轉成全連結層可接受的形狀。

C 直接將卷積輸出接到全連結層，系統會自動轉換維度；

判斷重點 | 錯誤：線性層不會自動理解並攤平空間維度，通常會造成維度不合。

D 先對特徵圖做 Softmax，再輸入全連結層

判斷重點 | 錯誤：Softmax 通常用在分類 logits 之後，不是卷積特徵轉換成全連結輸入的方法。

原始題目

某自駕車公司的 AI 訓練團隊面臨標註成本高的問題，無法取得足夠的真實惡劣天氣（大雨、濃霧）駕駛場景資料，工程師提議使用合成資料（Synthetic Data）來補充訓練集。請問下列何者最能正確敘述合成資料在 AI 訓練中的角色？

題目與選項標注

題目重點：真實惡劣天氣駕駛資料少且標註昂貴，合成資料在 AI 訓練中扮演什麼角色？

判斷關鍵：合成資料擅長建立可控制、難蒐集與多樣化的訓練情境，但通常用來補充而非完全取代真實資料。

A

合成資料主要用於文字任務的資料擴增，影像任務仍需依賴真實資料；

判斷重點 | 錯誤：錯誤。模擬的大雨、濃霧、道路與物件影像正是常見用途。

B

合成資料可完全取代真實資料，直接用於模型訓練；

判斷重點 | 錯誤：合成與真實資料可能有領域落差，仍需用真實資料校正與驗證。

C

合成資料主要用於降低模型推論時的計算成本；

判斷重點 | 錯誤：它改善訓練資料覆蓋率，不直接改變模型推論計算量。

D

合成資料可在控制條件下產生多樣化場景，用於擴充訓練資料並提升模型的泛化能力

判斷重點 | 正確：正確。可補足少見或危險場景，提高模型對不同情境的適應。

原始題目

某廣告技術公司的點擊率（CTR）預測系統每天新增數百個用戶行為特徵（如新廣告位、新設備類型），特徵空間持續動態擴展。若採用傳統靜態模型每週批次重訓一次，會導致嚴重的模型過期問題。為在特徵空間頻繁變化的情況下維持模型即時準確度，最適合的模型架構方向為何？

題目與選項標注

題目重點：CTR 系統每天新增特徵，每週批次重訓造成模型過期，適合什麼架構方向？

判斷關鍵：關鍵字是「持續新增、需要即時適應、不想整個重訓」，直接對應增量學習。

A

採用傳統靜態羅吉斯迴歸（Logistic Regression），縮短批次重訓週期從每週改為每日；

判斷重點 | 錯誤：只縮短過期時間，仍需反覆全量訓練，未解決動態適應問題。

B

採用支援增量學習（Incremental Learning）的模型，使模型能隨新資料即時更新並適應新增特徵，而不需重新訓練整個模型；

判斷重點 | 正確：正確。模型可逐步吸收新資料與特徵資訊，降低完整重訓頻率。

C

採用固定架構的深度神經網路（DNN），每次有新特徵時重新定義輸入層後全量重訓；

判斷重點 | 錯誤：成本高、延遲大，正是題目想避免的方式。

D

改用預訓練圖神經網路（GNN），透過圖結構建立特徵間的關聯，自動應對新增特徵

判斷重點 | 錯誤：圖模型不會因為是 GNN 就自動支援任意新增特徵，且題幹沒有圖結構需求。

原始題目

某生物醫學研究機構正在建構一個整合「基因序列特徵」與「電子病歷文本特徵」的疾病風險預測模型。由於高維數值特徵和語意文本特徵的性質差異顯著，請問下列哪一種特徵處理與選擇策略最為合適？

題目與選項標注

題目重點：高維基因數值特徵與語意病歷文本性質不同，應如何處理再融合？

判斷關鍵：異質資料應先用各自合適的方法表示，再做 Feature Fusion；不要把不同語意空間過早混成同一矩陣。

A

將所有特徵合併為單一特徵矩陣後，使用主成分分析（PCA）進行降維，作為模型輸入；

判斷重點 | 錯誤：PCA 假設共同的數值空間，可能破壞文本語意表示，也忽略兩種模態結構差異。

B

採分層策略，先對基因序列特徵進行特徵選擇，再對文本特徵進行語意表示，最後將兩類特徵融合（Feature Fusion）後輸入模型；

判斷重點 | 正確：正確。各模態先專門處理，最後才在合適層次整合。

C

將所有特徵合併後，使用隨機森林（RandomForest）的特徵重要性進行一次性排序與篩選；

判斷重點 | 錯誤：一次性重要性排序難以妥善處理高維數值與語意向量的不同性質。

D

將文本特徵轉換為簡單統計特徵（如詞頻）後與基因特徵一併建模，以降低特徵處理複雜度

判斷重點 | 錯誤：簡單詞頻會丟失上下文語意，未充分利用病歷文本資訊。

原始題目

某公司希望開發一個工業零件瑕疵辨識分類模型，共有 10 個類別，但每類僅約 50 張人工標註影像（總計約 500 張）。由於標註成本高昂，短期內無法擴充資料集。在此情境下，工程師需要在有限標註資料下建構高效能模型。請問下列哪一種策略最為適合？

題目與選項標注

題目重點：10 類工業零件、每類約 50 張影像，短期無法增加標註，最合適的策略是什麼？

判斷關鍵：資料少時避免從零訓練大型模型；利用大型資料集已學到的視覺特徵，再微調到新任務。

A

使用在大型資料集預訓練完成的卷積神經網路（CNN），並進行遷移學習微調；

判斷重點 | 正確：正確。可在有限標註資料下取得較好的特徵起點並降低過擬合風險。

B

從頭訓練大型 Vision Transformer（ViT），完全使用現有 500 張影像；

判斷重點 | 錯誤：資料量通常不足，大型模型容易過擬合且訓練成本高。

C

使用 K-means 對影像進行分群，並直接將群集結果作為分類模型輸出；

判斷重點 | 錯誤：無監督群集不保證對應十個瑕疵類別，不能直接取代監督分類器。

D

複製既有的資料以增加標註影像數量，並從頭訓練深度 CNN 模型

判斷重點 | 錯誤：重複資料沒有新增資訊，只會放大既有樣本並增加過擬合。

原始題目

某製造廠開發產線瑕疵檢測模型時，資料集存在嚴重類別不平衡問題，其中良品約占 99%，瑕疵品僅占 1%。若直接使用原始資料進行訓練，模型容易偏向預測多數類別（良品），導致對少數類別（瑕疵品）辨識能力不足。在不調整模型架構與學習演算法的前提下，僅透過資料前處理方式改善此問題，下列何者最適當？

題目與選項標注

題目重點：良品 99%、瑕疵 1%，不改模型架構與演算法，只用資料前處理改善，應怎麼做？

判斷關鍵：題目限定「資料前處理」，因此應在樣本分布上處理；SMOTE 是少數類別過採樣方法。

A

使用 SMOTE 等過採樣方法進行少數類別擴增；

判斷重點 | 正確：正確。增加少數類別代表性，降低模型只學會預測良品的傾向。

B

加入 L1 / L2 正則化 (Regularization) 以防止過擬合；

判斷重點 | 錯誤：這是訓練 / 模型控制方式，並未重新平衡類別資料。

C

大幅增加深度神經網路的層數，以強化特徵萃取能力；

判斷重點 | 錯誤：屬架構改動，且更深不會自然解決 99:1 的樣本失衡。

D

複製更多良品數據，以進一步提升模型的準確率 (Accuracy)

判斷重點 | 錯誤：會使不平衡更嚴重，表面 Accuracy 可能更高但瑕疵 Recall 更差。

原始題目

某 IoT 平台接收工廠溫度感測器資料，發現在常態分佈（均值 25°C ，標準差 2°C ）的數萬筆紀錄中，出現數筆「 999°C 」的極端值，研判為感測器通訊錯誤（網路封包延遲導致數值溢位）所致，且該異常數值在實際情況下不可能發生。在進行模型訓練前的資料清洗階段，針對這類離群值，最適當的處理策略為何？

題目與選項標注

題目重點： $25^{\circ}\text{C} \pm 2^{\circ}\text{C}$ 的感測資料出現不可能的 999°C 通訊錯誤，訓練前應如何處理？

判斷關鍵：先用領域知識判定這是資料錯誤而非真實罕見事件；應移除或以穩健統計值填補。

A 保留所有原始數值，並使用平均數（Mean）作為特徵輸入模型；

判斷重點 | 錯誤：極端錯值會扭曲平均數與模型。

B 對數據進行 Z-score 標準化，使數值落於約 $[-3, 3]$ 範圍；

判斷重點 | 錯誤：標準化會縮放但不會修正錯誤值，而且 999°C 也會扭曲均值與標準差。

C 將 999°C 以獨熱編碼（One-Hot Encoding）轉為獨立類別特徵；

判斷重點 | 錯誤：溫度是連續數值，將錯誤值當成合法類別沒有意義。

D 刪除異常的 999°C 記錄，或以中位數（Median）進行填補

判斷重點 | 正確：正確。中位數對極端值較穩健；若紀錄可安全捨棄也可刪除。

原始題目

某 AI 平台工程師正在為多模態模型訓練系統規劃資料儲存架構，需要同時處理原始影像、非結構化文本，以及經過整理的結構化特徵資料。在此情境下，應如何選擇資料湖（Data Lake）與資料倉儲（Data Warehouse）的使用方式？

題目與選項標注

題目重點：多模態訓練同時有原始影像、非結構化文本與整理好的結構化特徵，應如何儲存？

判斷關鍵：資料湖適合保留大量原始、多格式資料；資料倉儲適合已整理、結構化且需穩定查詢的資料。

A

將原始影像與文本資料儲存在 Data Lake，將整理後的結構化特徵資料儲存在 Data Warehouse；

判斷重點 | 正確：正確。讓兩種平台各自處理最合適的資料型態與查詢需求。

B

將所有資料統一儲存在 Data Warehouse，以提升查詢效率；

判斷重點 | 錯誤：大型原始影像與非結構化文本不適合強制套入倉儲結構。

C

將所有資料統一儲存在 Data Lake，但犧牲結構化資料的查詢效率；

判斷重點 | 錯誤：雖可儲存，但題目要求合理分工；已整理特徵在倉儲中更方便治理與查詢。

D

僅將原始影像資料儲存在 Data Lake，其餘資料統一存入 Data Warehouse

判斷重點 | 錯誤：原始非結構化文本也適合先放資料湖，不應一概視為結構化資料。

原始題目

某智慧製造公司在產線上部署工業相機進行即時外觀瑕疵檢測，原先將影像傳至雲端進行 AI 推論，但因網路延遲與連線不穩導致系統無法滿足即時需求（需低於 200ms）。工程師因此改為將模型部署於產線端的邊緣裝置後，但仍未達系統需求。在不更換硬體設備的前提下，下列哪一組技術最能有效降低推論延遲，同時維持合理準確率？

題目與選項標注

題目重點：模型已移到產線邊緣裝置但仍超過 200ms；不換硬體且要維持合理準確率，如何降延遲？

判斷關鍵：INT8 量化可降低運算與記憶體負擔，是不換硬體時常見的推論最佳化。

A

減少訓練資料的使用數量，並重新訓練模型以提升推論效率；

判斷重點 | 錯誤：資料筆數影響訓練，不會直接讓部署後每次推論更快，還可能降低泛化。

B

使用批次推論（Batch Inference）處理多張影像以提升計算效率；

判斷重點 | 錯誤：可提高吞吐量，但等待湊批次可能增加單張端到端延遲，不適合嚴格即時需求。

C

採用模型集成（Model Ensemble），透過多模型投票提升準確率；

判斷重點 | 錯誤：會增加計算量與延遲，方向相反。

D

將模型由 FP32 量化為 INT8，並進行推論加速優化

判斷重點 | 正確：正確。降低數值精度與運算成本，通常能在可接受精度損失下提升速度。

原始題目

某 AI 影像辨識平台以單一 GPU 伺服器提供多租戶推論服務，系統長期觀察到 GPU 使用率約維持在 60% 左右，且在執行過程中可觀察到 GPU kernel 之間存在明顯閒置間隔，單次推論多以小批次方式執行。然而，在尖峰時段時，請求延遲會出現明顯波動甚至突增。同時，CPU 與記憶體資源使用率均未達瓶頸，且系統團隊已排除硬體、網路與請求併發控制異常。在此情境下，請判斷最可能造成問題的原因為何？

題目與選項標注

題目重點：GPU 長期約 60%，kernel 間有閒置、小批次推論，尖峰延遲突增；硬體、網路、併發控制已排除，最可能原因是什麼？

判斷關鍵：「小批次 + kernel 閒置 + GPU 未吃滿」共同指向排程與 batching 未有效填滿 GPU。

A

GPU 排程策略與批次大小設定不當，導致 GPU 運算單元未被有效利用；

判斷重點 | 正確：正確。工作太碎或排程空隙會降低 GPU 佔用，尖峰時排隊又造成尾端延遲。

B

請求併發控制機制不佳，導致多個請求同時搶占 GPUContext 資源造成延遲；

判斷重點 | 錯誤：題幹明示已排除請求併發控制異常，因此不是最可能原因。

C

GPU 硬體效能不足，無法支撐推論負載；

判斷重點 | 錯誤：平均只用約 60% 且存在閒置，證據更像利用率問題而非純算力不足。

D

模型未進行量化優化，導致推論計算成本過高

判斷重點 | 錯誤：量化可能改善效能，但無法直接解釋 kernel 閒置與小批次造成的低利用率。

原始題目

某保險公司將理賠金額預測模型正式部署上線，MLOps 團隊設計監控機制。三個月後模型整體均方根誤差（RMSE）無明顯變化，但業務單位反映高額理賠案件的預測誤差明顯增加。經分析，高額理賠案件僅佔約 5% 的樣本比例，且未被監控機制及時發現。請問最可能的設計缺陷為何？

題目與選項標注

題目重點：整體 RMSE 不變，但只占 5% 的高額理賠誤差大增且未被監控發現，缺陷是什麼？

判斷關鍵：少數族群的惡化會被整體平均稀釋；應依金額區間切片監控，而非只看單一總體值。

A 監控頻率不足，應由每日批次監控改為即時串流監控；

判斷重點 | 錯誤：即使提高頻率，仍只看整體 RMSE，5% 族群仍可能被掩蓋。

B 高額理賠案件屬於長尾分布，難以透過監控指標偵測，因此無法透過監控機制發現問題；

判斷重點 | 錯誤：可以透過分群 / 切片指標、尾端誤差與高額族群專屬門檻監控。

C RMSE 無法有效反映高額誤差，應改以平均絕對誤差（MAE）作為主要監控指標；

判斷重點 | 錯誤：方向錯誤；平方項使 RMSE 通常比 MAE 更強調大誤差。問題是聚合方式，不是 RMSE 完全無效。

D 僅監控整體 RMSE，未針對不同理賠金額區間進行分群監控

判斷重點 | 正確：正確。分群後才能看到高額少數樣本的局部效能退化。

原始題目

某電商平台的演算法工程師開發了一個新版商品推薦模型，在離線 A/B 測試中，新模型的各项評估指標（AUC、NDCG@10）均顯著優於現行線上模型。然而，離線測試無法完全反映真實使用者的互動行為（點擊、購買、停留時間）。在正式全面上線前，若希望在可控制風險下量化真實業務指標，應採用下列何種線上驗證策略？

題目與選項標注

題目重點：離線 AUC、NDCG 都較好；全面上線前，要在可控風險下量測真實 CTR、CVR，應採何策略？

判斷關鍵：必須真的讓一小部分使用者看到新模型，才能量測其互動；同時又不能一次全面放量。

A

影子模式（Shadow Mode）：新舊模型同時產生預測，但僅顯示舊模型結果，於後端比較輸出差異；

判斷重點 | 錯誤：新模型只在後端產生結果，使用者仍看到舊模型，因此無法量測新推薦造成的真實 CTR / CVR。

B

回測（Backtesting）：使用歷史日誌模擬模型表現作為上線依據；

判斷重點 | 錯誤：仍是歷史資料上的離線驗證，不能完全反映現在的使用者互動。

C

金絲雀發布（CanaryRelease）：將 1—5% 使用者流量導向新模型，量測 CTR、CVR 等指標並逐步擴量；

判斷重點 | 正確：正確。用少量流量觀察真實業務指標與風險，再決定是否擴量。

D

負載測試（Load Testing）：於測試環境進行高流量壓力測試後直接全面上線

判斷重點 | 錯誤：負載測試檢查容量與效能，不能驗證推薦對真實業務行為的影響。

原始題目

某 MLOps 工程師正在設計 AI 模型的推論服務 API，需要處理使用者上傳的高解析度影像（平均 5MB）進行即時分類。在 RESTful API 設計時，選擇 HTTP 請求方法與資料傳輸格式的最佳實踐為何？

題目與選項標注

題目重點：RESTful API 接收平均 5MB 高解析度影像，HTTP 方法與格式的最佳實踐是什麼？

判斷關鍵：大型二進位資料應放 Request Body；POST 適合提交推論工作，multipart 或 octet-stream 適合檔案 / 位元流。

A 使用 HTTP GET 方法，將影像資料 Base64 編碼後附加於 URL Query String 中；

判斷重點 | 錯誤：URL 長度有限、Base64 增加體積，且 GET 不適合在查詢字串承載大型上傳內容。

B 採用 HTTP POST 請求，將影像資料以 multipart/form-data 或 application/octet-stream 傳輸於 Request Body；

判斷重點 | 正確：正確。資料放請求本文，可帶檔案欄位或直接傳二進位流。

C 使用 HTTP PUT 方法，透過 Content-Type: application/xml 傳遞影像資料；

判斷重點 | 錯誤：PUT 通常表示建立 / 完整替換指定資源；XML 也不是高效率的影像二進位格式。

D 要求客戶端下載模型於本地推論，僅回傳分類結果

判斷重點 | 錯誤：這改變部署模式，沒有回答伺服器影像推論 API 的傳輸設計需求。

原始題目

某 AI 平台整合多個外部 AI 微服務（語音辨識 API、NLP 分析 API、知識圖譜查詢服務），在高峰期間某外部服務偶發延遲或逾時（Timeout），導致請求鏈路壅塞，最終造成平台級服務中斷（Cascading Failure）。為從架構層面預防此類連鎖故障，最有效的設計模式為何？

題目與選項標注

題目重點：外部 AI 微服務偶發延遲與逾時，造成請求鏈壅塞及 Cascading Failure，最有效的架構模式是什麼？

判斷關鍵：斷路器在錯誤率或逾時超標時暫停呼叫故障服務，快速失敗或回退，避免資源被持續拖住。

A

將所有外部 API 呼叫改為同步串行處理，並取消逾時限制，確保每個請求皆完成後再繼續；

判斷重點 | 錯誤：會讓慢服務拖住更久，使壅塞與連鎖故障更嚴重。

B

為外部服務導入斷路器模式（CircuitBreaker），在異常時暫停呼叫並提供替代回應；

判斷重點 | 正確：正確。隔離故障依賴並讓它有恢復窗口，保護整體平台。

C

擴充各微服務的執行緒池（Thread Pool）上限，以提升併發處理能力；

判斷重點 | 錯誤：可能暫時容納更多阻塞工作，但也可能消耗更多資源，沒有隔離故障來源。

D

停用服務健康檢查，減少不必要的額外負載

判斷重點 | 錯誤：會降低發現與隔離異常服務的能力，風險更高。

原始題目

某醫院計劃建立混合雲 AI 平台：使用公有雲 GPU 叢集進行 CT 影像模型訓練，但基於 HIPAA (Health Insurance Portability and Accountability Act) 法規要求，患者影像原始資料不得離開醫院院內環境。下列何者最符合「利用公有雲算力訓練模型」與「不傳輸原始患者資料」雙重限制的技術方案？

題目與選項標注

題目重點：要利用公有雲算力，又要求患者原始影像不得離開院內，最符合雙重限制的是什麼？

判斷關鍵：Federated Learning 的辨識點是「資料留在本地，只交換模型更新並集中聚合」。

A

將患者影像資料以 AES-256 加密後上傳至公有雲，並於雲端解密後進行模型訓練；

判斷重點 | 錯誤：原始資料仍離開醫院，且在雲端被解密，不符合限制。

B

在院內部署同態加密 (Homomorphic Encryption) 模組，對推論請求進行加密處理；

判斷重點 | 錯誤：選項描述的是推論加密，不是題目要求的多方訓練與雲端聚合方案。

C

採用聯邦學習 (Federated Learning) 於院內訓練模型，僅傳送模型更新至雲端聚合，原始資料不外流；

判斷重點 | 正確：正確。原始影像保留在院內，雲端負責彙整更新。

D

建立專線 VPN 連接醫院與雲端，以網路層安全保護資料傳輸

判斷重點 | 錯誤：VPN 保護傳輸通道，但原始資料仍被傳到雲端。

原始題目

某電商平台將新的推薦模型部署至線上系統，為降低風險，團隊採用漸進式部署策略 (Phased Rollout)，先將新模型流量從 5% 逐步提升至 100%。在部署初期，團隊發現轉換率 (Conversion Rate) 略有提升，但在流量提升至 30% 時，系統延遲 (Latency) 明顯上升，且部分使用者體驗變差。請問在此情境下，最適當的下一步策略為何？

題目與選項標注

題目重點：新模型流量升到 30% 後轉換率略升，但延遲明顯增加、體驗變差，下一步應怎麼做？

判斷關鍵：漸進部署的目的就是在擴大影響前發現問題；有負面技術指標時先暫停擴量並修正。

A

立即將新模型全面部署至 100%，以觀察整體效果並評估系統表現變化；

判斷重點 | 錯誤：會把已知延遲問題放大到所有使用者，違反漸進式控風險原則。

B

還原 (Rollback) 至舊模型並停止新模型測試流程，以確保系統穩定與使用者體驗品質；

判斷重點 | 錯誤：模型有正向轉換訊號，延遲也可能優化；直接終止過於武斷。

C

維持目前 30% 流量並持續觀察，即使延遲問題存在也暫不進行調整；

判斷重點 | 錯誤：會持續傷害部分使用者，也沒有處理根因。

D

暫停流量提升，針對延遲問題進行效能分析與優化後再繼續部署

判斷重點 | 正確：正確。保留目前驗證成果，同時把風險控制在有限流量。

原始題目

某銀行的信用卡風控模型已穩定上線一年，主要用於偵測盜刷交易提醒。近期在未對模型或特徵工程進行調整的情況下，系統觀察到深夜電商交易的核准率明顯上升，盜刷攔截率下降，但模型 AUC 幾乎維持不變，且交易金額、地區與裝置等特徵分布未出現明顯變化。進一步分析發現，疫情後使用者行為改變，使原本被視為高風險的交易型態逐漸轉為一般消費。下列何者最能敘述此現象的原因？

題目與選項標注

題目重點：輸入特徵分布沒明顯改變，但疫情後行為改變，使原高風險交易型態變成一般消費，這是什麼現象？

判斷關鍵：輸入 X 沒變，但「同樣 X 對應的風險 Y」變了，就是特徵與標籤關係改變的 Concept Drift。

A 資料漂移 (Data Drift)，因輸入特徵分布發生變化；

判斷重點 | 錯誤：資料漂移指輸入特徵分布改變；題幹已說金額、地區、裝置等分布沒有明顯變化。

B 訓練與服務偏差 (Training-Serving Skew)，因線上與離線特徵處理不一致；

判斷重點 | 錯誤：沒有線上與離線特徵處理不一致的證據。

C 概念漂移 (Concept Drift)，因特徵與目標標籤之間的關聯性改變；

判斷重點 | 正確：正確。消費行為改變，使特徵與盜刷標籤之間的關係改變。

D 決策閾值偏移 (Threshold Shift)，因分類門檻設定不當導致預測偏差

判斷重點 | 錯誤：題幹沒有顯示門檻被更動；根因是交易型態的意義改變。

原始題目

某零售電商平台已建立模型監控儀表板，用於追蹤線上推薦模型的運作狀態與效能表現。維運工程師需判斷哪些指標屬於「線上持續監控（Continuous Monitoring）」的範疇。下列指標中，哪一項最不適合在即時監控系統中追蹤，而應改由離線實驗追蹤系統管理？

題目與選項標注

題目重點：哪一項最不適合放在線上持續監控，而應交給離線實驗追蹤系統？

判斷關鍵：先分清楚「訓練時發生什麼」與「上線後發生什麼」；Epoch、學習率、超參數屬訓練實驗。

A

訓練實驗中每個 Epoch 的學習率（Learning Rate）變化曲線與超參數（Hyperparameter）設定軌跡；

判斷重點 | 正確：正確。這些是離線訓練過程的實驗中繼資料，不是線上服務即時狀態。

B

線上推論 API 的 P50/P95/P99 回應延遲與每日請求量（RPS）趨勢；

判斷重點 | 錯誤：屬典型線上服務健康與容量監控。

C

輸入特徵分佈的族群穩定性指數（PopulationStabilityIndex,PSI），偵測資料漂移；

判斷重點 | 錯誤：可用於上線後偵測資料分布漂移。

D

模型預測結果分佈（如 CTR）與定期回收的人工標註結果之對比

判斷重點 | 錯誤：屬線上模型表現與概念漂移監控。

原始題目

某醫療團隊建立肺炎診斷系統，採用晚期融合（Late Fusion）策略，將胸腔 X 光影像與病患問診文字分別進行預測後再整合結果。測試發現，當問診紀錄品質不佳（如描述簡短或資訊缺漏）時，整體模型效能僅小幅下降。關於此現象，下列何者最不可能為其原因？

題目與選項標注

題目重點：影像與問診文字各自預測後再融合；文字品質差時整體效能只小幅下降，哪個最不可能是原因？

判斷關鍵： Late Fusion 是在各模態已各自完成特徵處理或預測後才整合；「輸入階段融合特徵」描述的是 Early Fusion。

A

各模態獨立進行預測，可降低單一模態品質不佳對整體結果的影響

判斷重點 | 錯誤：合理。影像支路仍可保有有效訊號。

B

融合階段可調整不同模態的權重，使低品質模態影響降低

判斷重點 | 錯誤：合理。決策融合可依可靠度或訓練結果調整各模態影響。

C

各模態使用獨立模型，使錯誤不會在特徵層被放大

判斷重點 | 錯誤：合理。模態間在較晚階段才互相影響。

D

晚期融合會在輸入階段整合多模態特徵，因此能避免低品質資料影響

判斷重點 | 正確：正確答案。這其實是 Early Fusion 的描述，因此最不可能解釋題目現象。

試題與答案來源：115 年第一次 AI 應用規劃師中級能力鑑定公告試題，第一科：人工智慧技術應用與規劃。

觀念依據：《AI 應用規劃師（中級）學習指引－科目 1 人工智慧技術應用規劃》。本頁為學習整理，並非官方解析。