

114 年第二次・公告試題

第二科 逐題答案解析

完整保留 50 題題幹、選項、圖表與程式碼，逐項說明正確與錯誤原因，並標出官方講義頁碼。

原題完整保留

圖表 / 程式碼

A~D 逐項解析

原順序 / 主題排序

閱讀方式：50 題全部直接呈現，不需點擊展開。綠色選項為公告答案；每題下方的「題目重點」與「判斷重點」是研讀標注。

1

Z-score 的方向與距離

機率統計・原題第 1 題

答案 D

原始題目

若某數據點的 Z 分數 (Z-Score) = 2，請問代表下列哪一種意涵？

題目與選項標注

題目重點：Z=2 表示觀測值位於平均值上方 2 個標準差。

判斷關鍵： $Z=(x-\mu)/\sigma$ ；正號代表高於平均。

A

代表該數據點之原始數值為 2；

判斷重點 | 錯誤：Z 分數不是原始數值。

B

該數據點比平均值低 2 個標準差；

判斷重點 | 錯誤：低於平均 2 個標準差應是 $Z=-2$ 。

C

代表數據為異常值；

判斷重點 | 錯誤：是否異常要看門檻， $Z=2$ 不必然就是異常。

D

該數據點比平均值高 2 個標準差

判斷重點 | 正確：正確；高於平均值 2 個標準差。

講義 3.1 | 標準分數 | 講義第 3-5~3-8 頁

官方講義觀念對應

原始題目

使用 Python 的 pandas 套件處理各商品銷售數據（變數為 df）時，若需 計算「總銷售額」欄位的敘述性統計量（如平均值、標準差等），應使用 下列哪一種語法？

題目與選項標注

題目重點：Series.describe() 一次輸出 count、mean、std、min、四分位數與 max。

判斷關鍵：題目要多個敘述統計量，不只是總和。

A

`df['總銷售額'].sum();`

判斷重點 | 錯誤：sum 只算總和。

B

`df['總銷售額'].describe();`

判斷重點 | 正確：正確；describe 回傳常用敘述統計摘要。

C

`df['總銷售額'].sort_values();`

判斷重點 | 錯誤：sort_values 只排序。


D

`df['總銷售額'].stats()`

判斷重點 | 錯誤：Pandas Series 沒有 stats() 這個標準方法。

原始題目

附圖為某資料之分佈圖，此圖資料之偏態（Skewness）值較有可能為下列 哪個選項？



原公告試題中的偏態分布圖

題目與選項標注

題目重點：圖中資料集中於高值，尾巴向左延伸，因此為負偏態， $\text{Skewness} < 0$ 。

判斷關鍵：偏態方向看長尾指向，不看最高峰位置。

A

$\text{Skewness} < 0$ ；

判斷重點 | 正確：正確；左長尾對應負偏態。

B

$\text{Skewness} > 0$ ；

判斷重點 | 錯誤：正偏態應是尾巴向右。

C

$\text{Skewness} = 0$ ；

判斷重點 | 錯誤：對稱分布才較接近 0。

D

無法計算 Skewness

判斷重點 | 錯誤：有觀測資料即可計算偏態。

原始題目

累積分佈函數（Cumulative Distribution Function, CDF）可用於描述 隨機變數的機率分佈特性，其數學定義為下列何者？

題目與選項標注

題目重點：連續變數的 CDF $F(x)=P(X\leq x)=\int_{-\infty}^x f(t)dt$ 。

判斷關鍵：CDF 的關鍵字是「累積」。

A

機率密度函數（Probability Density Function, PDF）的平均值；

判斷重點 | 錯誤：平均值不是 CDF 定義。

B

機率密度函數（Probability Density Function, PDF）的積分；

判斷重點 | 正確：正確；CDF 為 PDF 從負無限到 x 的積分。

C

機率密度函數（Probability Density Function, PDF）的離散總和；

判斷重點 | 錯誤：離散型才以機率質量累加，題目指 PDF。

D

機率密度函數（Probability Density Function, PDF）的標準差

判斷重點 | 錯誤：標準差是離散程度指標。

原始題目

在進行資料前處理時，若使用 Label Encoding 將類別變數轉換為數字型態，下列何者為最常見的潛在風險？

題目與選項標注

題目重點：把無序類別編成 0、1、2 可能讓模型誤以為類別有大小或距離。

判斷關鍵：名目類別通常用 One-Hot 或能原生處理類別的模型。

A

無法處理缺值；

判斷重點 | 錯誤：缺值可先處理，不是 Label Encoding 的核心風險。

B

會引入類別之間的虛假順序關係；

判斷重點 | 正確：正確；整數碼可能引入不存在的順序。

C

無法擴展至新資料；

判斷重點 | 錯誤：新類別確實需另處理，但不是最常見的根本風險。

D

記憶體佔用過高

判斷重點 | 錯誤：Label Encoding 通常比 One-Hot 省記憶體。

原始題目

在進行資料分析時，會遇到類別型（Categorical）與數值型（Numerical）資料格式。關於這兩種資料格式的處理，下列敘述何者不正確？

題目與選項標注

題目重點：標準化使平均為 0、標準差為 1；壓縮到 0~1 是 Min-Max Scaling。

判斷關鍵：題目問不正確，抓混淆兩種縮放法的敘述。

A

One-Hot 編碼（One-Hot Encoding）會將類別變數轉換為多維二元向量，適用於無序（Nominal）類別資料，但在高基數（High Cardinality）特徵下可能造成維度爆炸問題；

判斷重點 | 錯誤：One-Hot 的用途與高基數風險正確。

B

標籤編碼（Label Encoding）會以整數表示不同類別，若應用於無序（Nominal）資料，可能導致模型誤將編碼值解讀為具數值大小關係的特徵；

判斷重點 | 錯誤：Label Encoding 對名目資料的風險正確。

C

標準化（Standardization）透過將資料平移與縮放，使其平均值為 0、標準差為 1，可在多數距離型演算法中改善收斂速度，並同時將數值範圍壓縮至 0 至 1 之間；

判斷重點 | 正確：不正確；標準化後範圍不限定在 0~1。

D

對連續變數進行分箱（Binning）可提升模型可解釋性，但若分段方式未依據資料分佈特性設計，可能導致資訊損失或邊界偏誤

判斷重點 | 錯誤：分箱可提升解釋性，也可能造成資訊損失。

原始題目

在資料庫的 ACID 特性中，下列何者為「原子性 (Atomicity)」的正確定義？

題目與選項標注

題目重點：Atomicity 確保一筆交易的操作全部成功，否則全部回復。

判斷關鍵：記憶 all-or-nothing。

A

所有資料欄位必須為相同型別；

判斷重點 | 錯誤：欄位型別一致不是原子性。

B

每次交易需以批次方式執行；

判斷重點 | 錯誤：是否批次執行與原子性無關。

C

交易不可分割，需完全成功或完全失敗；

判斷重點 | 正確：正確；交易不可被部分提交。

D

系統會自動同步交易資料至所有節點

判斷重點 | 錯誤：同步到所有節點屬複寫 / 一致性議題。

原始題目

資料科學家為分析顧客行為，利用現有欄位「銷售金額」與「瀏覽次數」，計算出新變數「銷售金額/瀏覽次數」。此動作屬於下列哪一類特徵工程方法？

題目與選項標注

題目重點：用銷售金額除以瀏覽次數建立比率，是 Feature Derivation。

判斷關鍵：新欄位由現有欄位運算而來。

A

特徵選擇 (Feature Selection)；

判斷重點 | 錯誤：沒有從候選特徵中挑選子集。

B

特徵衍生 (Feature Derivation)；

判斷重點 | 正確：正確；運算產生新變數。

C

特徵轉換 (Feature Transformation)；

判斷重點 | 錯誤：轉換通常改變單一特徵尺度或表示。

D

分箱處理 (Binning)

判斷重點 | 錯誤：沒有把連續值切成區間。

原始題目

在進行數值特徵的標準化（Normalization）時，若資料中存在極端值（Outliers），下列哪一種方法最適合使用？

題目與選項標注

題目重點：RobustScaler 使用中位數與 IQR，較不受離群值影響。

判斷關鍵：Min-Max 與均值 / 標準差都容易被極端值拉動。

A

Min-Max 正規化（Min-Max Scaling）；

判斷重點 | 錯誤：Min-Max 的最大最小值會被離群值主導。

B

Z-score 標準化（Z-score Normalization）；

判斷重點 | 錯誤：Z-score 的平均與標準差也受離群值影響。

C

穩健縮放（Robust Scaling）；

判斷重點 | 正確：正確；以 median、IQR 進行穩健縮放。

D

標準分箱（Standard Binning）

判斷重點 | 錯誤：分箱不是數值縮放的首選。

原始題目

下列哪一種情境最適合應用異常偵測（Anomaly Detection）技術？

題目與選項標注

題目重點：即時交易中找出偏離平常模式的可疑紀錄，是 Anomaly Detection。

判斷關鍵：異常偵測找少數不尋常事件，不是一般預測。

A

根據歷史銷售資料預測特定商品在旺季期間是否會出現供貨短缺，以 提前調整庫存策略；

判斷重點 | 錯誤：供貨短缺屬需求 / 庫存預測。

B

透過信用風險模型預測顧客是否可能發生違約，以輔助核貸決策；

判斷重點 | 錯誤：信用違約通常是監督式分類。

C

即時分析金融交易資料流，偵測與平常交易行為明顯不同的可疑交易 紀錄；

判斷重點 | 正確：正確；可疑交易是典型異常偵測。

D

監控線上服務平台的使用者登入次數，預測次日的登入量變化趨勢

判斷重點 | 錯誤：次日登入量屬時間序列預測。

原始題目

若一家公司需即時監控大量物聯網裝置的異常行為，下列哪一種組合最適 合此應用？

題目與選項標注

題目重點：大量裝置與低延遲異常偵測需要可擴展平台及串流 / 即時分析。

判斷關鍵：關鍵是大量、連續、低延遲。

A

傳統關聯式資料庫+圖形視覺化；

判斷重點 | 錯誤：傳統單一資料庫難處理大規模即時流。

B

批次資料處理+雲端備份；

判斷重點 | 錯誤：批次處理延遲太高。

C

大數據平台+即時資料分析技術；

判斷重點 | 正確：正確；大數據平台搭配即時分析。

D

Word 文件+手動標註

判斷重點 | 錯誤：文件與人工標註無法即時擴展。

原始題目

在處理分類問題時，若某一類樣本數明顯少於其他類別，研究人員可能採用隨機過採樣（Random Oversampling）以平衡資料比例，此方法最常造成下列哪一種問題？

題目與選項標注

題目重點：Random Oversampling 重複少數類原樣本，容易讓模型記住重複資料而過擬合。

判斷關鍵：複製資料沒有增加新的少數類結構。

A

增加過擬合風險；

判斷重點 | 正確：正確；重複樣本提高過擬合風險。

B

降低模型的收斂速度；

判斷重點 | 錯誤：未必造成收斂速度降低。

C

減少資料總筆數數量；

判斷重點 | 錯誤：過採樣會增加而非減少筆數。

D

導致訓練資料欄位缺失

判斷重點 | 錯誤：不會導致欄位缺失。

原始題目

下列何者為同態加密（Homomorphic Encryption）技術的核心特性？

題目與選項標注

題目重點：Homomorphic Encryption 允許直接對加密資料計算，解密結果對應明文計算。

判斷關鍵：核心不是隱藏身分，而是不解密仍可計算。

A

將資料轉換為匿名識別碼以隱藏身分；

判斷重點 | 錯誤：匿名化是去識別化。

B

對資料進行標準化處理以提升模型精度；

判斷重點 | 錯誤：標準化是資料前處理。

C

自動偵測與排除異常值；

判斷重點 | 錯誤：異常偵測與同態加密無關。

D

可直接在加密狀態下進行數據運算

判斷重點 | 正確：正確；可在密文狀態下運算。

原始題目

某組資料共 10 項標籤如下：A, A, A, A, A, B, B, B, B, B 若該標籤僅有 A、B 兩種，請問這組資料的「正規化吉尼不純度 (Normalized Gini impurity)」為何？

題目與選項標注

題目重點：A、B 各占 0.5，原始 $Gini=1-0.25-0.25=0.5$ ；二分類最大值也為 0.5，正規化後為 1。

判斷關鍵：Normalized Gini = 原始 Gini 除以該類別數下的最大值。

A 0；

判斷重點 | 錯誤：0 代表完全純淨，不符各半。

B 0.42；

判斷重點 | 錯誤：0.42 不是此分布的 Gini。

C 0.84；

判斷重點 | 錯誤：0.84 也非正規化結果。

D 1

判斷重點 | 正確：正確；各半是二分類最大混雜，正規化為 1。

原始題目

某家客服中心統計資料發現，平均每小時會接到約 20 通顧客來電，但每分鐘的來電數量不固定，可能為 0、1、2 通不等。這些來電事件彼此獨立，且在短時間內，發生的機率與時間長短成正比。若要以機率模型描述「每分鐘接到幾通來電」的機率分佈，下列哪一種最適合使用？

題目與選項標注

題目重點：獨立事件、固定平均率、在時間區間內計數，適合 Poisson。

判斷關鍵：次數用 Poisson；等待時間常用 Exponential。

A

均勻分佈 (Uniform distribution)；

判斷重點 | 錯誤：均勻分布不符合固定率事件計數。

B

指數分佈 (Exponential distribution)；

判斷重點 | 錯誤：指數分布描述事件間等待時間。

C

卜瓦松分佈 (Poisson distribution)；

判斷重點 | 正確：正確；每分鐘來電數是 Poisson 計數。

D

常態分佈 (Normal distribution)

判斷重點 | 錯誤：常態分布不是此離散低次數的首選。

原始題目

某金融科技公司以 Z 分數 (Z-Score) 監控交易金額異常狀況。若交易金額平均為新台幣 2,000 元，標準差為 400 元，某筆交易金額為 3,200 元，且公司以 $|Z| \geq 3$ 判定為異常值 (Outlier)，下列判斷何者最為正確？

題目與選項標注

題目重點： $(3200-2000)/400=3$ ，且題設 $|Z| \geq 3$ 即標記異常。

判斷關鍵：先代公式，再注意門檻包含等號。

A

該筆交易的 Z 分數為 3，應標記為異常值；

判斷重點 | 正確：正確； $Z=3$ 且達異常門檻。

B

該筆交易的 Z 分數為 2.5，屬於合理變異範圍；

判斷重點 | 錯誤：差值 1200 除以 400 不是 2.5。

C

該筆交易的 Z 分數為 2，顯示模型標準差估計過高；

判斷重點 | 錯誤：不是 $Z=2$ 。

D

該筆交易的 Z 分數為 1.5，無須納入異常檢測

判斷重點 | 錯誤：也不是 $Z=1.5$ 。

原始題目

某電商公司欲利用顧客行為資料建立消費預測模型，其中「會員等級」欄位包含「一般、白金、黑卡」三種類別。若模型採用梯度提升樹（Gradient Boosting Tree）演算法，資料科學家在進行特徵編碼時應特別注意下列何種情況？

題目與選項標注

題目重點：把類別任意編為整數可能讓樹的切分產生人為順序與特徵重要性偏差。

判斷關鍵：會員等級若有真實順序可明確定義；若只是標籤不可任意編碼。

A

應優先採用獨熱編碼（One-Hot Encoding），以減少類別之間的相依性與記憶體使用量；

判斷重點 | 錯誤：One-Hot 通常增加而非減少記憶體。

B

直接使用標籤編碼（Label Encoding）可能使模型誤判類別間存在順序關係，導致特徵重要性偏誤；

判斷重點 | 正確：正確；任意整數順序可能影響分裂。

C

使用目標編碼（Target Encoding）會自動消除過擬合（Overfitting）風險；

判斷重點 | 錯誤：Target Encoding 仍可能過擬合，需交叉驗證與平滑。

D

若類別數量較少，建議先使用主成分分析（Principal Component Analysis, PCA）進行降維

判斷重點 | 錯誤：PCA 不適合直接處理少量類別碼。

原始題目

某人工智慧團隊使用分散式資料庫 (Distributed Database) 儲存模型訓練資料，並在更新訓練樣本時啟用多節點交易。若其中一個節點在交易過程中發生錯誤，但系統仍確保整體資料不會出現部分更新、最終狀態維持一致，下列何者最能說明此現象？

題目與選項標注

題目重點：節點失敗時不允許部分更新，必須全提交或全 Rollback，對應 Atomicity。

判斷關鍵：題幹聚焦「部分更新」。

A

系統透過原子性 (Atomicity) 確保交易必須全部成功或全部回復 (Rollback)；

判斷重點 | 正確：正確；原子性保證 all-or-nothing。

B

系統透過一致性 (Consistency) 確保交易完成後資料符合完整性規則；

判斷重點 | 錯誤：一致性是交易前後符合完整性規則，非此敘述焦點。

C

系統透過隔離性 (Isolation) 避免多筆交易同時存取或修改相同資料；

判斷重點 | 錯誤：隔離性處理併發互相干擾。

D

系統透過持久性 (Durability) 確保交易一旦提交，其結果將永久保留於資料庫中

判斷重點 | 錯誤：持久性保證已提交結果不丟失。

原始題目

某製造企業導入上萬台物聯網 (IoT) 感測器以進行設備健康監測。系統 需在毫秒級回應異常事件，並同時將完整資料保留於雲端供後續 AI 模型 訓練與分析。若企業希望兼顧即時性、資料完整性與可擴展性，下列哪一 種資料流程設計最符合此目標？

題目與選項標注

題目重點：邊緣節點先低延遲反應，串流框架持續處理，資料湖完整保存供後續訓練。

判斷關鍵：三個需求分別對應 edge、stream、lake。

A

感測器 → 雲端 API Gateway → 分散式資料庫 → 批次特徵工程 (→ 模型推論；

判斷重點 | 錯誤：雲端往返與批次特徵工程難達毫秒回應。

B

感測器 → MQTT Broker → 雲端資料倉儲 → 即時儀表板 → 模型再訓練；

判斷重點 | 錯誤：直接進資料倉儲不適合原始高頻流與即時推論。

C

感測器 → 邊緣運算節點 → 流式資料處理框架 (Stream Processing Framework) → 雲端資料湖 → 模型推論；

判斷重點 | 正確：正確；兼顧低延遲、完整保存與擴展。

D

感測器 → 本地快取層 → RESTful API → 雲端報表系統) → 模型批 次更新

判斷重點 | 錯誤：報表與批次更新不符合即時異常處理。

原始題目

某銀行計畫將信用風險評估模型部署至雲端平台，以便即時分析客戶交易行為。由於涉及大量敏感金融資料，銀行要求雲端服務商在不解密原始資料的情況下仍能執行模型運算。為達成此目標，最適合採用下列哪一項技術？

題目與選項標注

題目重點：銀行要求雲端不解密仍能運算，應用同態加密。

判斷關鍵：題幹幾乎就是 HE 的定義。

A

在上傳資料前進行匿名化 (Anonymization)，僅保留可識別代碼供比對使用；

判斷重點 | 錯誤：匿名化仍可能需明文運算，也不等於密文計算。

B

利用雜湊 (Hash) 函數轉換資料，以確保模型可追蹤但無法還原個資；

判斷重點 | 錯誤：雜湊不可支援一般模型數值運算。

C

採用資料本地化 (Data Localization) 策略，將所有模型訓練限制於內部伺服器中；

判斷重點 | 錯誤：資料本地化違反要在雲端運算的前提。

D

透過同態加密 (Homomorphic Encryption)，讓雲端系統能直接在加密資料上執行運算，解密後結果與原始資料一致

判斷重點 | 正確：正確；密文上計算，解密後得到對應結果。

原始題目

某資料分析師設計在業務績效報告時，希望單一頁面中同時呈現多區域、不同產品線的銷售趨勢變化，並確保主管能在短時間內掌握整體資料走向。若依據 Edward Rolf Tufte 的數據密度（Data Density）原則，下列哪一種設計方式最能符合該概念？

題目與選項標注

題目重點：在同一圖表以顏色區分產品線、比例一致且標註清楚，可在有限空間提供多維比較。

判斷關鍵：高密度仍要維持可讀性與正確比例。

A

將每個區域的銷售資料分成多張獨立折線圖，以避免資訊重疊；

判斷重點 | 錯誤：拆成多圖降低同頁比較密度。

B

使用顏色區分產品線，於同一圖表中整合多區域趨勢線，保持比例一致且標註清晰；

判斷重點 | 正確：正確；整合資訊又保留清楚編碼。

C

移除所有輔助線與標籤，僅保留主要折線以凸顯趨勢；

判斷重點 | 錯誤：移除所有標籤會失去可解讀性。

D

將資料轉換為表格形式，確保數值精確呈現並取代圖表視覺化

判斷重點 | 錯誤：表格精確但不如圖表快速掌握趨勢。

原始題目

某投資研究員希望分析四檔科技類股（A、B、C、D）每日報酬率的變化趨勢，以判斷這些股票之間是否存在高度相關性與共變動性，並評估投資組合分散風險的程度。若研究員希望以單一圖表快速呈現各股票間的關聯強度與方向，下列哪一種視覺化呈現方式最適合？

題目與選項標注

題目重點：四檔股票兩兩相關的方向與強度可用 correlation matrix heatmap 一次呈現。

判斷關鍵：多變數兩兩關係＝矩陣＋熱力圖。

A

為每檔股票各自繪製直方圖（Histogram）以比較報酬率分佈；

判斷重點 | 錯誤：直方圖只看各自分佈。

B

針對任兩檔股票繪製散佈圖並加上趨勢線（Regression Line）；

判斷重點 | 錯誤：散佈圖一次只呈現一對，需多張圖。

C

使用雙軸折線圖（Dual-axis Line Chart）同時顯示四檔股價變化；

判斷重點 | 錯誤：雙軸不適合四個序列，也不能直接表達相關強度。

D

熱力圖（Heatmap）配合相關係數矩陣（Correlation Matrix）

判斷重點 | 正確：正確；單圖呈現全部兩兩相關係數。

原始題目

某研究團隊以單樣本 t 檢定 (one-sample t-test) 檢驗「新行銷策略後 的平均月銷售額是否與原本的 100 萬元不同」，顯著水準設定為 $\alpha = 0.05$ 。檢定結果顯示：p 值=0.08，且 95% 信賴區間為 [95 萬元, 108 萬元]。根據上述結果，下列敘述何者正確？

題目與選項標注

題目重點：p=0.08>0.05，且 100 萬位於 95% CI 內，因此無法拒絕 H_0 。

判斷關鍵：雙尾檢定中，虛無值在信賴區間內與不顯著相呼應。

A

因 p 值 < 0.05，可拒絕虛無假設；

判斷重點 | 錯誤：0.08 並不小於 0.05。

B

若顯著水準改為 0.10，仍不顯著；

判斷重點 | 錯誤：若 $\alpha=0.10$ ， $0.08 < 0.10$ 會顯著。

C

因 100 萬元落在信賴區間內，無法拒絕虛無假設；

判斷重點 | 正確：正確；100 萬仍是資料相容的母體平均。

D

信賴區間寬度僅與顯著水準有關

判斷重點 | 錯誤：區間寬度也受樣本數、變異程度影響。

原始題目

某企業建置生成式 AI 系統，利用大量客服紀錄與產品評論資料訓練語言模型，以自動生成客服回覆與知識摘要。由於資料來源多樣，且包含非結構化文字、影像與表格資訊，團隊希望在不降低模型效能的前提下，提升資料處理效率與一致性，下列哪一種資料處理策略最適合？

題目與選項標注

題目重點：多來源非結構化與結構化資料適合進 Data Lake，再用 Spark / Ray 做可擴展處理並接訓練管線。

判斷關鍵：關鍵是多樣資料、大規模與一致流程。

A

建立資料湖 (Data Lake) 結構，並以 Apache Spark 或 Ray 進行分散式資料預處理與特徵抽取，再串接至模型訓練管線 (Pipeline)；

判斷重點 | 正確：正確；兼顧彈性儲存、平行運算與管線一致性。

B

採用單節點高效能伺服器搭配批次處理模式，集中執行資料清理與格式轉換；

判斷重點 | 錯誤：單節點成為擴展與可靠度瓶頸。

C

將所有文字資料轉換為向量，並以資料庫索引方式直接餵入語言模型訓練；

判斷重點 | 錯誤：不是所有資料都只需轉向量，仍需清理與治理。

D

使用生成式模型先行自動清理資料內容，再將結果輸入至下游訓練流程

判斷重點 | 錯誤：讓生成模型自行清理缺乏可控性與一致驗證。

原始題目

某電商資料團隊繪製顧客單筆消費金額的箱型圖後發現：四分位距（IQR）範圍極小，但上鬚線拉得很長，且在高金額區域有多筆離群值。若希望協助行銷部門依據消費層級設計分群策略，下列哪一種視覺化方式 最有助於凸顯不同消費層級間的差異？

題目與選項標注

題目重點：消費金額高度右偏、跨度大時，用 log scale 壓縮尺度，可同時看一般與高消費群差異。

判斷關鍵：不要為了好看直接刪離群值。

A

以對數刻度繪製箱型圖或長條圖，放大高金額消費族群的變化差異；

判斷重點 | 正確：正確；對數尺度適合長尾金額。

B

移除所有離群值，確保資料呈現集中分布；

判斷重點 | 錯誤：離群值可能正是高價值客群，不能任意移除。

C

採用等距分箱（Equal-Width Binning）方式分群；

判斷重點 | 錯誤：等距分箱在長尾資料常造成大多數集中同一箱。

D

改以折線圖（Line Chart）觀察時間變化趨勢

判斷重點 | 錯誤：題目比較層級，不是時間趨勢。

原始題目

某串流影音平台運用關聯規則學習 (Association Rule Learning) 分析 用戶的觀影行為，發現若使用者觀看了科幻影集，則有較高機率接著觀看 超級英雄電影。分析顯示，同時觀看這兩種類型的使用者約佔全部觀影紀錄的 12%，而觀看科幻影集的使用者中，有 50%也觀看了超級英雄電影，該規則的提升度 (Lift) 為 1.8。根據上述資訊，下列哪一項推論最為正確？

題目與選項標注

題目重點：Confidence=50% 表示看科幻者中一半也看英雄片；Lift=1.8>1 表示正向關聯。

判斷關鍵：Support 反映覆蓋，Confidence 反映條件機率，Lift 比較獨立基準。

A

支持度 (Support) 過低，代表此規則不具任何商業價值；

判斷重點 | 錯誤：12% 不代表毫無商業價值。

B

提升度 (Lift) 大於 1 表示兩種類型內容無關，僅屬於隨機重疊；

判斷重點 | 錯誤：Lift>1 不是無關，而是正向關聯。

C

信賴度 (Confidence) 為 50%，代表觀看科幻影集者有明顯傾向觀看 超級英雄電影；

判斷重點 | 正確：正確；50% 是規則的條件命中率，且 Lift 支持正關聯。

D

同時觀看比例僅 12%，代表兩種類型互相排斥

判斷重點 | 錯誤：12% 同時觀看不代表互斥。

原始題目

某金融科技公司分析每日上億筆交易資料，以監控客戶轉帳金額分佈與異常波動。由於資料量極大，為兼顧效率與準確度，團隊決定採用「近似分位數 (Approximate Quantile)」方法進行資料摘要統計。下列何者最能正確反映該技術的核心目的？

題目與選項標注

題目重點：以可控誤差換取低記憶體與高速度，支援巨量與串流資料的分位數估計。

判斷關鍵：Approximate 的核心就是精度－效能折衷。

A

確保每個分位值的結果完全精確，即使計算時間較長；

判斷重點 | 錯誤：完全精確不是近似方法的目的。

B

利用機器學習模型預測分位數位置，以減少統計計算量；

判斷重點 | 錯誤：通常用摘要 / sketch，不是用 ML 預測分位數。

C

僅能對結構化資料進行批次處理，無法應用於即時資料流；

判斷重點 | 錯誤：近似分位數可用於串流。

D

在可容忍誤差範圍內，快速估算分位值以支援即時分析

判斷重點 | 正確：正確；在容忍誤差內快速估算。

原始題目

若在高維度 (>500 維) 的資料上應用 DBSCAN (Density-Based Spatial Clustering of Applications with Noise) 演算法，卻發現所有資料點 皆被判定為雜訊 (Noise)，下列何者為最有可能的原因？

題目與選項標注

題目重點：高維空間中點對距離趨於相近，密度概念失去區辨力， ϵ 難以設定，點易全成雜訊。

判斷關鍵：先考慮降維或選擇更合適距離 / 方法。

A

高維下距離變化趨同，導致 ϵ (Epsilon) 閾值選擇失效；

判斷重點 | 正確：正確；距離集中使 ϵ 判斷失效。

B

使用錯誤的距離函數 (Distance Function)；

判斷重點 | 錯誤：距離函數可能影響，但題幹最典型原因是高維距離集中。

C

MinPts 參數設得太小；

判斷重點 | 錯誤：MinPts 太小通常更容易形成群，不會讓全部成雜訊。

D

資料過度標準化導致特徵消失

判斷重點 | 錯誤：標準化不會讓特徵消失。

原始題目

某團隊在開發風險評估模型時，使用主成分分析（Principal Component Analysis, PCA）進行降維。輸入資料包含三個數值欄位：「交易金額（單位：新台幣）」、「交易次數（次／月）」與「年齡（歲）」，其數值量級分別約為 10^5 、 10^1 與 10^2 。分析人員直接將原始數據帶入 PCA，結果第一主成分（PC1）幾乎完全由「交易金額」主導。下列哪一項作法或判斷最合理？

題目與選項標注

題目重點：PCA 最大化變異，原始量級大的交易金額會主導共變異數；應先把各特徵標準化。

判斷關鍵：量級差異大時，PCA 前縮放。

A

這是正常現象，金額本身變異較大，應主導主要成分；

判斷重點 | 錯誤：若目標是公平反映各變數，不能接受單純量級主導。

B

若改用特徵選擇法，可自動解決變數量級問題；

判斷重點 | 錯誤：特徵選擇不會自動消除量級。

C

可刪除「交易金額」欄位以平衡各主成分的影響；

判斷重點 | 錯誤：刪除重要欄位會損失資訊。

D

在進行 PCA 前應先進行標準化（Standardization），以避免因數值尺度差異造成特徵偏誤

判斷重點 | 正確：正確；標準化避免尺度偏誤。

原始題目

某行銷團隊想了解「廣告預算」與「銷售金額」之間的關聯程度。經繪製 散佈圖後發現兩者呈現明顯線性趨勢，且資料中無明顯離群值（Outliers）。若希望衡量兩者之間線性關係的強度與方向，下列哪一種 方法最適合？

題目與選項標注

題目重點：兩個連續變數呈線性且無明顯離群值，Pearson r 可量化方向與強度。

判斷關鍵：題目要相關，不是預測誤差。

A

均方根誤差（Root Mean Squared Error, RMSE）；

判斷重點 | 錯誤：RMSE 衡量預測誤差。

B

共變異數（Covariance）；

判斷重點 | 錯誤：Covariance 有方向但受單位尺度影響，不便比較強度。

C

皮爾森相關係數（Pearson Correlation Coefficient）；

判斷重點 | 正確：正確；Pearson 標準化到 $-1 \sim 1$ 。

D

平均絕對誤差（Mean Absolute Error, MAE）

判斷重點 | 錯誤：MAE 也是預測誤差。

原始題目

某電商團隊觀察到，每位顧客對廣告推播的點擊行為可視為一次伯努利試驗（Bernoulli Trial），單次點擊成功機率為 $p=0.4$ 。當推播對象擴增至 5,000 位顧客時，團隊想快速預估「成功點擊總數」的分佈情形，以進行模型效能模擬與預測。若希望以常態分佈（Normal Distribution）近似原始分佈，下列哪一項判斷最為合理？

題目與選項標注

題目重點： $n=5000$ 、 $p=0.4$ 時 $np=2000$ 、 $n(1-p)=3000$ ，均大於 5，可用常態近似。

判斷關鍵：條件不是只看 n 大，也要成功與失敗期望次數都足夠。

A

因樣本數極大，可直接以常態分佈近似二項分佈（Binomial Distribution）；

判斷重點 | 錯誤：說「只要樣本大就直接近似」少了必要條件。

B

只有當 np 與 $n(1-p)$ 皆大於 5 時，才能以常態分佈作近似；

判斷重點 | 正確：正確； np 與 $n(1-p)$ 皆足夠大。

C

常態近似只適用於 $p=0.5$ 的情況；

判斷重點 | 錯誤： p 不必等於 0.5。

D

無論樣本數多大，二項分佈都不能以常態分佈近似

判斷重點 | 錯誤：大樣本且條件符合時可以近似。

原始題目

某電信公司導入生成式 AI 客服系統，利用過去對話紀錄與用戶行為資料 訓練語言模型，在資料治理與合規審查過程中，團隊發現模型可能會在回答中生成包含真實姓名、電話或交易資訊的內容。為確保系統符合個資法 及生成式 AI 的安全與隱私要求，下列哪一項作法最符合實務可行及法規 原則？

題目與選項標注

題目重點：先匿名化 / 偽匿名化降低訓練資料風險，再對生成輸出做敏感資訊偵測與稽核，形成多層防護。

判斷關鍵：生成式 AI 隱私要同時治理輸入資料與輸出。

A

在訓練資料前進行資料匿名化 (Anonymization) 或偽匿名化 (Pseudonymization) 處理，並建立輸出內容稽核機制；

判斷重點 | 正確：正確；符合資料最小化與持續監控。

B

改以強化學習 (Reinforcement Learning) 微調模型，使模型學習避免產出真實資訊；

判斷重點 | 錯誤：強化學習不能保證不洩漏真實資訊。

C

採用同態加密 (Homomorphic Encryption) 以加密所有文字輸入，確保模型無法辨識任何個資；

判斷重點 | 錯誤：同態加密並不等於模型無法辨識任何個資，且成本高。

D

僅設定模型回覆時不顯示用戶姓名，即可視為隱私防護完成

判斷重點 | 錯誤：只遮姓名忽略電話、交易等其他個資。

原始題目

某金融機構的量化分析師在建立資產風險評估模型時，發現報酬率資料分佈明顯非對稱，且出現多次極端損失事件，使得傳統假設常態分佈的模型無法準確反映真實風險。若希望在不依賴常態分佈假設的前提下，採取更能捕捉資料極端情況的建模策略，下列哪一種方法最為合適？

題目與選項標注

題目重點：Quantile Regression 不要求殘差常態，可直接建模低尾分位數，適合極端損失風險。

判斷關鍵：題目要求不依賴常態且關注尾端。

A

採用線性迴歸模型（Linear Regression Model），以常態分佈殘差（Residuals）為基礎進行推估；

判斷重點 | 錯誤：線性迴歸加常態殘差仍依賴題目要避免的假設。

B

使用平均數（Mean）與標準差（Standard Deviation）估計波動範圍；

判斷重點 | 錯誤：均值與標準差難描述偏態厚尾。

C

將資料裁剪至 $\pm 3\sigma$ 範圍內以排除異常值影響；

判斷重點 | 錯誤：裁掉極端損失會消除最重要的風險訊號。

D

採用分位數回歸模型（Quantile Regression Model），聚焦於尾部分位（Tail Quantiles）以評估極端風險

判斷重點 | 正確：正確；直接聚焦 tail quantiles。

原始題目

在圖形資料庫（Graph Database）中建模社群平台資料時，若每筆「按讚」行為都包含時間戳記（Timestamp）與裝置類型（Device Type）等資訊。若希望同時保留使用者與貼文之間的互動關係，並能有效查詢「按讚」的行為屬性，下列哪一種設計方式最為合適？

題目與選項標注

題目重點：使用者與貼文是節點，「按讚」是關係邊，時間與裝置可存為邊的 properties。

判斷關鍵：互動行為的資訊屬於關係本身。

A

將「按讚」視為節點（Node），與使用者建立邊（Edge）；

判斷重點 | 錯誤：可建事件節點，但此題直接邊屬性更自然有效。

B

將「按讚」資訊作為邊的屬性（Property）儲存，連結使用者與被按讚的貼文節點；

判斷重點 | 正確：正確；保留兩節點關係及互動屬性。

C

把「按讚」資訊直接寫入使用者節點中作為屬性；

判斷重點 | 錯誤：寫進使用者節點無法表達對哪篇貼文按讚。

D

建立「按讚紀錄表」並將資料存入關聯式資料庫

判斷重點 | 錯誤：另存關聯表失去圖查詢優勢。

原始題目

某企業欲建構知識圖譜 (Knowledge Graph)，以整合內部的研究報告、專利資料與專家知識，並支援語意查詢與關聯推理。若希望模型能具備良好的語意擴展性與高效推理能力，下列哪一種圖模型設計最為合適？

題目與選項標注

題目重點：RDF 以 Subject—Predicate—Object 表達可互通語意，適合知識圖譜與推理。

判斷關鍵：知識圖譜的關鍵是明確語意關係與本體擴展。

A

僅以節點 (Node) 與邊 (Edge) 表示，所有資訊存放於節點屬性中；

判斷重點 | 錯誤：只用一般節點邊且把資訊塞屬性，語意規範不足。

B

將資料結構建為 RDF (Resource Description Framework) 三元組 (Subject—Predicate—Object)；

判斷重點 | 正確：正確；RDF 三元組利於語意查詢與推理。

C

使用文件型資料庫儲存內容，並以標籤 (Tag) 連接節點；

判斷重點 | 錯誤：文件標籤不具正式關係語意。

D

採用關聯式資料庫儲存對應關係，並搭配預建索引加速查詢

判斷重點 | 錯誤：關聯表可儲存，但語意擴展與推理較不自然。

原始題目

某研究人員欲使用線性迴歸模型（Linear Regression Model）分析變數 Y 與 X 之間的關係，但發現 Y 的分佈明顯右偏，且其變異數隨 X 的增大而增加。為滿足模型假設並提升配適效果，下列哪一種前處理方法最為合適？

題目與選項標注

題目重點：對正值 Y 做 Box-Cox 可減少右偏、穩定變異，讓線性模型假設更合理。

判斷關鍵：問題在 Y 的分布與殘差變異，不是 X 的尺度。

A

對 X 進行標準化（Standardization）；

判斷重點 | 錯誤：標準化 X 不會修正 Y 的右偏與異質變異。

B

對 Y 進行 Box-Cox 轉換（Box-Cox Transformation）；

判斷重點 | 正確：正確；Box-Cox 可同時改善偏態與變異穩定性。

C

對資料進行一次差分（First Differencing）；

判斷重點 | 錯誤：差分主要用於時間序列非平穩。

D

將 Y 中變異較大的樣本移除

判斷重點 | 錯誤：刪除高變異樣本會造成選擇偏差。

原始題目

若開發一個用於罕見疾病自動診斷的分類模型，目前資料集中確診樣本僅 佔不到 1%，且因為標註成本高，短期內無法取得更多資料。在此情況下，若希望提升模型對少數類的偵測能力，同時避免過擬合，下列哪一種 策略最為合理？

題目與選項標注

題目重點：相較單純複製，SMOTE 在少數類鄰居間合成新樣本，可改善平衡並降低直接記憶重複點的風險。

判斷關鍵：只在訓練資料內做 SMOTE，避免資料洩漏。

A

對少數類進行隨機過採樣 (Random Oversampling)；

判斷重點 | 錯誤：隨機過採樣重複樣本，過擬合風險較高。

B

對多數類進行欠採樣 (Random Undersampling)；

判斷重點 | 錯誤：欠採樣會丟掉大量多數類資訊。

C

使用 SMOTE (Synthetic Minority Over-sampling Technique) 生成 合成少數類樣本後再訓練分類模型；

判斷重點 | 正確：正確；合成少數類樣本後訓練。

D

僅使用現有資料調整模型決策閾值 (Decision Threshold) 以提升召回率

判斷重點 | 錯誤：只調閾值不增加少數類的學習訊號。

原始題目

一家製造廠評估新生產線推出後，產品良率是否較原生產線提升。工程師分別從兩條生產線各抽樣 100 件產品，原生產線良率為 95%，新生產線為 97%。若欲檢定兩條生產線良率的差異是否具有統計意義，下列哪一種方法最為合適？

題目與選項標注

題目重點：比較兩個獨立樣本的良率比例 95% 與 97%，應使用 two-proportion Z-test。

判斷關鍵：結果是比例，不是連續平均數。

A

雙樣本平均數 t 檢定 (Two-sample t-test)；

判斷重點 | 錯誤：t 檢定比較平均數。

B

雙比例 Z 檢定 (Two-proportion Z-test)；

判斷重點 | 正確：正確；兩組獨立比例差異。

C

卡方檢定 (Chi-square test)；

判斷重點 | 錯誤：2×2 卡方可得近似等價結論，但題目最直接方法是雙比例 Z。

D

變異數分析 (ANOVA)

判斷重點 | 錯誤：ANOVA 比較多組平均數。

原始題目

若評估一個新開發的腫瘤分類模型，其資料集中有 80% 的樣本來自良性病例。若直接使用 5-fold 交叉驗證（Cross-Validation）進行模型評估，可能導致模型效能評估出現偏差，為避免此問題，下列哪一種作法最合適？

題目與選項標注

題目重點：分層切分確保每折約 80/20，避免某折少數類過少造成指標不穩。

判斷關鍵：分類不平衡的交叉驗證要 stratify。

A

降低 K 值以減少交叉驗證次數；

判斷重點 | 錯誤：降低 K 不保證比例一致。

B

改為使用拔靴法（Bootstrap）；

判斷重點 | 錯誤：Bootstrap 也可能出現比例波動。

C

調整測試集使良性樣本比例更高，以模擬真實分佈；

判斷重點 | 錯誤：提高測試集良性比例會更失真。

D

使用分層交叉驗證（Stratified K-Fold Cross-Validation），以確保每折類別比例一致

判斷重點 | 正確：正確；每折維持類別分佈。

原始題目

請參考附圖，下列虛擬程式碼（pseudocode）最可能是在描述何種驗證法？

Input:

- data_set : 包含 N 筆資料的資料集
- model_training_function : 用來訓練模型的函式
- model_evaluation_function : 用來評估模型的函式

Output: 平均評估指標

Algorithm:

1. 初始化評估指標列表 metrics=[]
2. 對 i=1 到 N:
 - a. 將第 i 筆資料作為測試集 test_data
 - b. 將其餘 N-1 筆資料作為訓練集 train_data
 - c. 使用 train_data 訓練模型
 - d. 使用 test_data 做預測，計算 metric_i
 - e. 將 metric_i 加入 metrics
3. 計算 metrics 的平均值 mean_metric
4. 回傳 mean_metric

題目與選項標注

題目重點：程式每次取第 i 筆作 test，其餘 N-1 筆訓練，重複 N 次後平均指標，即 LOOCV。

判斷關鍵：一輪只留一筆測試資料。

A

Hold-out 驗證 (Hold-out Validation) ;

判斷重點 | 錯誤：Hold-out 只做一次固定切分。

B

留一交叉驗證 LOOCV (Leave-One-Out Cross Validation) ;

判斷重點 | 正確：正確；每筆都輪流當一次測試樣本。

C

K-fold 交叉驗證 (K-fold Cross Validation) ;

判斷重點 | 錯誤：一般 K-fold 每折含多筆，K 不一定等於 N。

D

拔靴法 (Bootstrap) 驗證

判斷重點 | 錯誤：Bootstrap 是有放回抽樣。

原始題目

請參考附圖，下列虛擬程式碼（pseudocode）最可能是在描述何種演算法？

Input: data_points (N 筆資料，每筆 D 個特徵)、K (群數)

Output: clusters、centroids

Algorithm:

1. 隨機選擇 K 個資料點作為初始中心
 2. 重複直到收斂：
 - a. 分群：計算每筆資料到各中心距離，指派給最近中心
 - b. 更新中心：計算各群資料點平均值作為新中心
 3. 當群中心不再變動時停止
- 回傳 clusters 與 centroids

題目與選項標注

題目重點：隨機選 K 個中心、依距離指派、重算各群平均中心、反覆到不變，就是 K-means。

判斷關鍵：指派最近中心 + 更新均值。

A

K-means 分群 (K-means Clustering)；

判斷重點 | 正確：正確；完全符合 K-means 迭代流程。

B

高斯混合模型分群 (Gaussian Mixture Model Clustering)；

判斷重點 | 錯誤：GMM 會估計機率與協方差並做軟分群。

C

階層式分群 (Hierarchical Clustering)；

判斷重點 | 錯誤：階層式分群合併或切分樹狀群集。

D

DBSCAN 分群 (Density-based Spatial Clustering of Applications with Noise Clustering)

判斷重點 | 錯誤：DBSCAN 依密度與鄰域擴展，不用中心均值。

原始題目

考慮某生產線每小時出現瑕疵品的個數符合卜瓦松分佈 (Poisson Distribution)，已知平均每小時產生 5 個瑕疵品，附圖程式碼展示資料處理，請問下列敘述何者正確？

```
import numpy as np
from scipy.stats import poisson
lambda_poisson = 5
print(poisson.pmf(5, lambda_poisson))
```

題目與選項標注

題目重點： $\lambda=5$ 是每小時平均發生率； $\text{PMF}(5)$ 是恰好 5 個； $\text{CDF}(10)$ 是至多 10 個。

判斷關鍵：分清平均率、恰好機率與累積機率。

A $\text{lambda_poisson} = 5$ 表示每小時最多 5 個瑕疵品；

判斷重點 | 錯誤： λ 是平均數，不是最大值。

B $\text{poisson.pmf}(5, \text{lambda_poisson})$ 表示小於 5 個瑕疵品的機率；

判斷重點 | 錯誤： $\text{pmf}(5)$ 是恰好 5，不是小於 5。

C 卜瓦松分佈的適用條件為事件彼此獨立，且平均發生率固定；

判斷重點 | 正確：正確；事件獨立且平均率固定。

D $\text{poisson.cdf}(10, 5)$ 表示大於或等於 10 個瑕疵品的機率

判斷重點 | 錯誤： $\text{cdf}(10,5)=P(X\leq 10)$ ，不是 $P(X\geq 10)$ 。

共用題組情境

一間遊戲市場研究公司正在分析全球電子遊戲銷售情況，並準備建立一份「熱銷遊戲銷售報告」。分析師取得一份名為 vgsales.csv 的資料集，內容包含全球銷量超過 10 萬份的電子遊戲清單。研究團隊希望透過這份資料，了解不同年份、平台與地區的銷售趨勢。

欄位：Name（遊戲名稱）、Platform（平台）、Year（發售年份）、Genre（類型）、Publisher（發行商）、NA_Sales / EU_Sales / JP_Sales / Other_Sales（各地區銷售量，百萬份）、Global_Sales（全球總銷售量，百萬份）。

請根據此資料情境回答第 43~47 題。

原始題目

分析師在載入資料後，檢視 Year 欄位的資料型態，發現它是 float64，而非一般年份常用的整數。他想知道這樣的情形為什麼會發生。請問下列 哪些原因可能導致這種狀況？原因 A：CSV 檔中 Year 欄位有缺失值(NaN)，導致 Pandas 自動將整欄轉為浮點數。原因 B：CSV 檔中的年份資料原本是字串(如 "2006")，Pandas 轉換時出錯而變成浮點數。原因 C：Pandas 預設會將所有數值型態讀取為 float64，不論資料是否為整數。原因 D：CSV 檔中的年份資料可能包含小數點(例如 2006.0)，因此被視為浮點數。

資料欄位概觀 (前 5 筆)：

Rank	Name	Platform	Year	Genre	Publisher	NA	EU	JP	Other	Global
1	Wii Sports	Wii	2006.0	Sports	Nintendo	41.49	29.02	3.77	8.46	82.74
2	Super Mario Bros.	NES	1985.0	Platform	Nintendo	29.08	3.58	6.81	0.77	40.24
3	Mario Kart Wii	Wii	2008.0	Racing	Nintendo	15.85	12.88	3.79	3.31	35.82
4	Wii Sports Resort	Wii	2009.0	Sports	Nintendo	15.75	11.01	3.28	2.96	33.00
5	Pokemon Red/Pokemon Blue	GB	1996.0	Role-Playing	Nintendo	11.27	8.89	10.22	1.00	31.37

```
data['Year']
0      2006.0
1      1985.0
2      2008.0
3      2009.0
4      1996.0
...
16597   2003.0
Name: Year, Length: 16598, dtype: float64
```

題目與選項標注

題目重點：整數欄含 NaN 時，傳統 NumPy dtype 常提升為 float；若原資料含 2006.0 也會讀成浮點。

判斷關鍵： Pandas 不會把所有整數一律讀為 float。

A

原因 B、原因 C；

判斷重點 | 錯誤：B 的字串轉換失敗通常會形成 object 或錯誤；C 也不正確。

B

原因 A、原因 D；

判斷重點 | 正確：正確；A 與 D 都可能造成 float64。

C

原因 A、原因 B、原因 D；

判斷重點 | 錯誤：B 不一定成立，且 A、D 才是題目最合理組合。

D

原因 C、原因 D

判斷重點 | 錯誤：C 錯；Pandas 可直接推斷整數型態。

原始題目

研究團隊接下來想要將 Year 欄位轉換為整數型態，以便後續進行年份趨勢分析。考慮到資料中可能包含缺失值 (NaN)，請選出最合適的轉換方式。

題目與選項標注

題目重點：Pandas 擴充型別 Int64 (大寫 I) 可同時表示整數與 pd.NA。

判斷關鍵：一般 int 無法容納 NaN。

A

```
data['Year'] = data['Year'].astype(int);
```

判斷重點 | 錯誤：有 NaN 時 `astype(int)` 會失敗。

B

```
data['Year'] = data['Year'].fillna(0).astype(int);
```

判斷重點 | 錯誤：用 0 填補會引入不存在的年份。

C

```
data['Year'] = data['Year'].fillna(1).astype(int);
```

判斷重點 | 錯誤：用 1 填補更不合理。

D

```
data['Year'] = data['Year'].astype('Int64');
```

判斷重點 | 正確：正確；nullable Int64 保留缺失值。

原始題目

為了觀察各遊戲平台的市場表現，分析師想要統計每個平台的全球銷售總額，並以長條圖呈現。請選出最能正確實現此分析的程式碼。

題目與選項標注

題目重點：依 Platform 分組後對 Global_Sales 加總，再繪製 bar。

判斷關鍵：題目要總額，聚合函數必須是 sum。

A

```
data.groupby("Platform")["Global_Sales"].sum().plot(kind="bar");
```

判斷重點 | 正確：正確；分組加總後畫長條圖。

B

```
data.groupby("Platform")["Global_Sales"].count().plot(kind="bar");
```

判斷重點 | 錯誤：count 計算遊戲筆數。

C

```
data["Platform"].value_counts().plot(kind="bar");
```

判斷重點 | 錯誤：value_counts 計算平台出現次數。

D

```
data.groupby("Platform")["Global_Sales"].mean().plot(kind="bar")
```

判斷重點 | 錯誤：mean 是平台平均銷量，不是總額。

原始題目

團隊希望比較北美、歐洲、日本及其他地區的整體銷售比例，並使用 seaborn 套件以長條圖的形式進行可視化分析。請選出能正確顯示這些地區銷售總額比例的程式碼。

題目與選項標注

題目重點：把四個地區欄位 melt 成 variable/value 長格式，barplot 搭配 estimator=sum 可比較各地區總額。

判斷關鍵：Seaborn 多系列聚合通常先轉 long format。

A

```
sns.countplot(x=["NA_Sales","EU_Sales","JP_Sales","Other_Sales"], data=data);
```

判斷重點 | 錯誤：countplot 只計筆數，不加總銷售值。

B

```
sns.lineplot(x="Platform", y=["NA_Sales","EU_Sales","JP_Sales","Other_Sales"], data=data);
```

判斷重點 | 錯誤：lineplot 的 y 不能直接用這個欄位清單表達總額比例。

C

```
sns.barplot(x="variable", y="value", data=pd.melt(data, value_vars=
["NA_Sales","EU_Sales","JP_Sales","Other_Sales"]), estimator=sum);
```

判斷重點 | 正確：正確；melt 後按地區加總畫長條。

D

```
sns.histplot(data[["NA_Sales","EU_Sales","JP_Sales","Other_Sales"]])
```

判斷重點 | 錯誤：histplot 顯示分布，不是地區總額比較。

原始題目

研究團隊想要知道在北美地區（NA）銷售成績最好的遊戲前五名，並希望以 seaborn 的條狀圖呈現結果。請選出能正確完成這項分析的程式碼。

題目與選項標注

題目重點：先用 `nlargest(5, "NA_Sales")` 找前五，再以 `Name` 與 `NA_Sales` 畫 `barplot`。

判斷關鍵：不能直接 `head`，除非資料已排序。

A `sns.barplot(x="NA_Sales", y="Name", data=data.head(5)) ;`

判斷重點 | 錯誤：`head(5)` 只是原始前五列。

B `sns.barplot(x="Name", y="NA_Sales", data=data.nlargest(5, "NA_Sales")) ;`

判斷重點 | 正確：正確；先依 `NA_Sales` 取最大五筆。

C `sns.lineplot(x="Name", y="NA_Sales", data=data.nlargest(5, "NA_Sales")) ;`

判斷重點 | 錯誤：`lineplot` 不適合離散遊戲排名。

D `sns.countplot(x="Name", y="NA_Sales", data=data)`

判斷重點 | 錯誤：`countplot` 不接受 `y` 數值聚合，也只計次數。

共用題組情境

使用銷售資料集 (marketing.csv) 進行迴歸分析，附圖程式碼展示資料載入與處理，請回答第 48~50 題。

原始題目

根據上述結果，下列何者正確？

```
import pandas as pd
df = pd.read_csv("marketing.csv")

>>> df.head()
   youtube  facebook  newspaper  sales
0    276.12    45.36    83.04   26.52
1     53.40     NaN    54.12   12.48
2     20.64    55.08    83.16   11.16
3    181.80    49.56    70.20   22.20
4    216.96    12.96    70.08   15.48

>>> df.describe()
count    youtube  facebook  newspaper    sales
mean    176.451000   27.820101   36.664800   16.827000
25%      89.250000   11.940000   15.300000   12.450000
50%     179.700000   27.000000   30.900000   15.480000
75%     262.590000   43.680000   54.120000   20.880000
max      355.680000   59.520000  136.800000   32.400000
```

題目與選項標注

題目重點：df.describe() 顯示 youtube 的 25% 為 89.25，因此 Q1=89.25。

判斷關鍵：50% 是中位數；75% 是 Q3。

A

資料集個數為 199 筆，變數個數為 4 個；

判斷重點 | 錯誤：資料列數為 200；facebook 非缺失 count 才是 199。

B

sales 變數的中位數是 16.827；

判斷重點 | 錯誤：sales 的平均數是 16.827，中位數為 15.48。

C

facebook 變數的第三四分位數(Q3)是 11.94；

判斷重點 | 錯誤：facebook 的 Q3 是 43.68，11.94 是 Q1。

D

youtube 變數的第一四分位數(Q1)是 89.25

判斷重點 | 正確：正確；youtube 25% 分位數為 89.25。

原始題目

參考下圖計算各變數的遺漏值(NaN)個數結果，下列何者正確？ 選項 A: df.isnull().sum() 選項 B: df.isNaN().sum() 選項 C: df.isna().sum() 選項 D: df.isnan().sum()

```
youtube      0
facebook     1
newspaper    0
sales        0
dtype: int64
```

題目與選項標注

題目重點：DataFrame.isnull() 與 isna() 都可判斷缺失值，再 sum() 得各欄 NaN 數。

判斷關鍵：Pandas 沒有 isNaN() / isnan() 這兩個 DataFrame 方法。

A

選項 D；

判斷重點 | 錯誤：只選 D 不對，isnan 不是標準 DataFrame 方法。

B

選項 B、選項 C、選項 D；

判斷重點 | 錯誤：B、D 都不是標準方法。

C

選項 A、選項 C；

判斷重點 | 正確：正確；A 與 C 等價可用。

D

選項 A、選項 B、選項 C

判斷重點 | 錯誤：包含不存在的 B，因此錯。

原始題目

考慮資料集已經填補遺漏值，參考下圖執行結果，下列何者正確？ A：空格 1 完整語法 `reg = LinearRegression().fit(y, X)` B：空格 1 完整語法 `reg = LinearRegression().fit(X, y)` C：`print(reg.coef_)` 結果為包括截距項等 4 個係數值 D：空格 2 完整語法 `sm.OLS(X2, y).fit()` E：`model_sm` 迴歸模型的所有迴歸係數在 $\alpha=0.05$ 之下具有顯著的解釋力 F：截距項係數值為 3.5561

```
from sklearn.linear_model import LinearRegression
import statsmodels.api as sm
X = df[['youtube', 'facebook', 'newspaper']]
y = df['sales']
reg = 空格 1
print(reg.coef_)
X2 = sm.add_constant(X)
model_sm = 空格 2
print(model_sm.summary())
```

OLS 主要結果：

const	coef	3.5561	P> t	0.000
youtube	coef	0.0455	P> t	0.000
facebook	coef	0.1891	P> t	0.000
newspaper	coef	-0.0006	P> t	0.914

題目與選項標注

題目重點：scikit-learn 使用 `fit(X,y)`；statsmodels 使用 `sm.OLS(y,X2)`。截距是 3.5561，newspaper 的 $p=0.914$ 不顯著。

判斷關鍵：先確認自變數 / 依變數順序，再讀係數與 p 值。

A

B、C、F

判斷重點 | 錯誤：A 的 `fit(y,X)` 顛倒，C 也把 `coef_` 誤含截距。

B

B、F

判斷重點 | 正確：正確；B 是 `fit(X,y)`，F 的截距 3.5561 由 OLS 表可讀得。

C

A、C、D、F

判斷重點 | 錯誤：A、C、D 都有變數順序或係數解讀錯誤。

D

B、E

判斷重點 | 錯誤：E 錯；newspaper 的 p 值 0.914 大於 0.05。

試題與答案來源：114 年第二次 AI 應用規劃師中級能力鑑定公告試題，第二科：大數據處理分析與應用。

觀念依據：《AI 應用規劃師（中級）學習指引－科目 2 大數據處理分析與應用》。本頁為依官方資料製作的學習整理，並非官方解析。