

115 年第一次・公告試題

第二科 逐題答案解析

完整保留 50 題題幹、選項、公式、附表與程式碼，逐項說明正確與錯誤原因，並標出官方講義頁碼。

原題完整保留

公式 / 程式碼

A~D 逐項解析

原順序 / 主題排序

閱讀方式：50 題全部直接呈現，不需點擊展開。綠色選項為公告答案；每題下方的「題目重點」與「判斷重點」是研讀標注。

1

盒鬚圖的集中、變異與偏態

機率統計・原題第 1 題

答案 A

原始題目

工程師使用盒鬚圖 (BoxPlot) 比較三個城市的房價分布，觀察到城市 A 的盒子很短但鬚很長，城市 B 的盒子很長且對稱，城市 C 的中位數位置明顯偏向盒子下方。依統計圖形判讀原則，下列敘述何者正確？

題目與選項標注

題目重點：盒子短代表中間 50% 集中；鬚長表示尾端延伸，離群點仍須看圖上的獨立點；中位數偏向盒子下方通常顯示上半部較分散。

判斷關鍵：先分別看 IQR (盒長)、鬚、離群點與中位數位置。

A

城市 A 中段房價集中但存在極端值；城市 C 中位數偏低，資料呈右偏分布；

判斷重點 | 正確：A 同時抓到 A 的中段集中、長尾，以及 C 的右偏判讀。

B

城市 A 房價集中且離群值少；城市 C 資料呈左偏分布；

判斷重點 | 錯誤：盒鬚長不能推出離群值少，C 也不是左偏。

C

城市 B 的盒子較長代表房價變異較大；城市 C 呈左偏分布；

判斷重點 | 錯誤：B 的盒長確實反映變異較大，但把 C 判成左偏使整句錯誤。

D

盒鬚圖無法判斷偏態，需搭配直方圖才能得出以上結論

判斷重點 | 錯誤：盒鬚圖可初步判斷集中、離散與偏態，不必然只能靠直方圖。

講義 3.1 | 箱形圖 | 講義第 3-7~3-8 頁

官方講義觀念對應

原始題目

下圖為吉尼不純度 (GiniImpurity) 的計算公式，在決策樹 (DecisionTree) 中，吉尼不純度用於評估節點分裂的品質。關於吉尼不純度，下列敘述何者不正確？

$$\text{Gini} = 1 - \sum_{i=1}^k p_i^2$$

題目與選項標注

題目重點：Gini 公式中的 p_i 是第 i 類樣本所占比例，不是樣本數。

判斷關鍵：比例平方後加總；完全同類時 $\text{Gini}=0$ 。

A

公式中的 p_i 代表第 i 類在該節點中的樣本數，並直接帶入公式計算；

判斷重點 | 正確：A 把 p_i 說成樣本數，直接代入會破壞機率公式，故為不正確敘述。

B

公式中的 k 代表節點內資料的類別數量；

判斷重點 | 錯誤： k 就是節點中的類別數。

C

吉尼不純度用於衡量節點內資料的類別混雜程度，數值越高代表越混雜；

判斷重點 | 錯誤：數值越高表示類別越混雜。

D

當節點內所有樣本屬於同一類別時（完全純淨），吉尼不純度為 0

判斷重點 | 錯誤：所有樣本同類時該類比例為 1，其餘為 0，Gini 為 0。

原始題目

某物流平台要預測「每小時客服來電數量」，資料顯示平均每小時 12 通，且來電事件彼此獨立，並在固定時間區間內發生率穩定。工程師在選擇機率模型時，應優先考慮哪個分布？若實際資料的變異數明顯大於平均數，應如何調整？

題目與選項標注

題目重點：固定時間內獨立事件的發生次數適合 Poisson；若變異數明顯大於平均數，改用 Negative Binomial。

判斷關鍵： Poisson 的典型條件是平均數約等於變異數。

A

使用常態分布 (Normal Distribution) ；變異數偏大時改用 t 分布；

判斷重點 | 錯誤：常態分布不適合直接描述低值、非負的計數事件，t 分布也不是過度離散修正。

B

使用卜瓦松分布 (Poisson Distribution) ；變異數 > 平均數時改用負二項分布 (Negative Binomial) ；

判斷重點 | 正確：正確；先用 Poisson，過度離散時改用負二項分布。

C

使用卜瓦松分布 (Poisson Distribution) ；變異數偏大時增加樣本數即可修正；

判斷重點 | 錯誤：增加樣本數不會修正資料生成機制中的過度離散。

D

使用二項分布 (Binomial Distribution) ；變異數偏大時改用卜瓦松分布 (Poisson Distribution)

判斷重點 | 錯誤：二項分布需要固定試驗次數；本題描述的是固定時間內事件計數。

原始題目

某工程師使用 MLflow 進行實驗追蹤，評估三種不同學習率（0.001、0.01、0.1）對同一模型在驗證資料集上的損失表現。每種學習率皆以不同隨機種子重複訓練 10 次，形成三組彼此獨立的樣本資料。經檢查後，這些資料近似常態分布且變異數相近。工程師希望判斷三組平均損失是否存在顯著差異，同時避免因進行多次兩兩比較而提高第一類型錯誤率。請問下列何者為最適合採用的統計方法？

題目與選項標注

題目重點：三組獨立、近似常態且變異數相近，要一次檢查平均數是否有差異，使用 One-Way ANOVA。

判斷關鍵：三組以上平均數，不宜反覆做兩兩 t 檢定。

A

單因子變異數分析（One-Way ANOVA）；

判斷重點 | 正確：正確；一次檢驗三組平均數可控制整體第一類型錯誤。

B

獨立樣本 t 檢定（Independent Samples t-test）；

判斷重點 | 錯誤：獨立樣本 t 檢定只直接比較兩組，反覆比較會累積第一類型錯誤。

C

卡方獨立性檢定（Chi-Square Test）；

判斷重點 | 錯誤：卡方檢定用於類別次數或比例，不比較連續損失的平均數。

D

Wilcoxon 符號等級檢定（Wilcoxon Signed-Rank Test）

判斷重點 | 錯誤：Wilcoxon signed-rank 用於成對且非參數的兩組資料。

原始題目

某 AI 團隊在模型上線後，透過監控系統持續追蹤輸入特徵的分布變化，系統使用 Z-score (Z) 作為異常判斷依據，並設定當 $|Z| \geq 2$ 時需觸發警示。假設該特徵近似常態分布，某次監控中發現某特徵值的 Z-score 為 -2 ，請問就實務判讀而言，此數值最可能代表什麼意義？

題目與選項標注

題目重點： $Z=-2$ 表示觀測值比平均值低 2 個標準差，也達到題設 $|Z| \geq 2$ 的警示門檻。

判斷關鍵：負號只表示低於平均，不代表在分布之外。

A

該特徵值低於該特徵歷史平均值 2 個標準差；

判斷重點 | 正確：正確；Z 的絕對值是距離，負號表示方向。

B

該特徵值高於該特徵歷史平均值 2 個標準差；

判斷重點 | 錯誤：高於平均 2 個標準差應是 $Z=+2$ 。

C

該特徵值等於該特徵的歷史平均值；

判斷重點 | 錯誤：等於平均值時 $Z=0$ 。

D

Z-score 為負值代表該數值位於母體分布之外，無法以常態分布解釋

判斷重點 | 錯誤：負 Z 仍可由常態分布解釋。

原始題目

在 AI 模型評估的假說檢定框架中，「女士品茶」實驗是理解型一 / 型二錯誤的經典案例。實驗中某女士宣稱能分辨 8 杯奶茶中哪 4 杯先加牛奶，若以顯著水準 $\alpha=0.05$ 進行假說檢定，下列敘述何者不正確？

題目與選項標注

題目重點： $p < \alpha$ 時拒絕 H_0 ； $p \geq \alpha$ 時只能說證據不足以拒絕，不能證明 H_0 為真。

判斷關鍵：題目問不正確，抓「接受 / 確認虛無假說」這種過度結論。

A

虛無假說 (H_0) 為「女士無此能力 (隨機猜測)」，對立假說 (H_1) 為「女士確實有此能力」；

判斷重點 | 錯誤： H_0 與 H_1 的設定正確。

B

在 $\alpha=0.05$ 下，若女士完全答對 (8 選 4 全對)，其 p 值約為 $1/70 \approx 0.014$ ，小於顯著水準，可達統計顯著；

判斷重點 | 錯誤：8 選 4 全對的機率為 $1/70$ ，低於 0.05。

C

若女士完全答對且 p 值 $< \alpha$ ，則拒絕虛無假說，統計上支持女士有此能力；

判斷重點 | 錯誤： $p < \alpha$ 時拒絕 H_0 ，支持有辨識能力。

D

若女士未完全答對，則「接受虛無假說」，代表確認女士無此能力

判斷重點 | 正確：未全對不必然代表確認無能力；只能依 p 值判斷是否拒絕 H_0 。

原始題目

某醫療 AI 研究團隊開發了一套個人化用藥劑量推薦系統，並設計實驗評估其效果。研究團隊招募 40 名高血壓患者，分別在導入 AI 推薦系統前後各測量一次收縮壓，且資料近似常態分布。研究目標是判斷同一批患者在依據 AI 推薦調整用藥劑量前後，血壓是否有顯著差異。請問此研究情境應選用哪種統計檢定方法？

題目與選項標注

題目重點：前後測來自相同 40 人，觀測值彼此配對，應檢定每人的差值。

判斷關鍵：同一人前後測＝成對資料。

A

獨立樣本 t 檢定 (Independent Samples t-test) ；

判斷重點 | 錯誤：獨立樣本 t 檢定假設兩組個體獨立，不合本題。

B

成對樣本 t 檢定 (Paired Samples t-test) ；

判斷重點 | 正確：正確；以每位患者前後差值進行成對 t 檢定。

C

單因子變異數分析 (One-Way ANOVA) ；

判斷重點 | 錯誤：ANOVA 可擴充到多組，但兩次成對測量不需要。

D

魏克遜符號等級檢定 (Wilcoxon Signed-Rank Test)

判斷重點 | 錯誤：資料已近似常態，優先用參數式的成對 t 檢定。

原始題目

某咖啡店聲稱其平均外送時間為 36 分鐘，母體標準差為 16 分鐘。顧客保護團體抽樣 9 筆訂單，發現平均外送時間為 40 分鐘。若採用右尾 Z 檢定 ($H_1: \mu > 36$)，顯著水準 $\alpha = 0.05$ (臨界值 $Z_{0.05} = 1.645$)，請問 Z 值與檢定結果為何？(參考公式如下圖)

$$Z = (\bar{x} - \mu_0) \div (\sigma / \sqrt{n})$$

題目與選項標注

題目重點： $Z = (40 - 36) / (16 / \sqrt{9}) = 0.75$ ，小於右尾臨界值 1.645，因此不拒絕 H_0 。

判斷關鍵：先算標準誤 16/3，再比臨界值。

A

Z $\approx$ 0.08，拒絕虛無假說；

判斷重點 | 錯誤：Z 值算錯且結論錯。

B

Z $\approx$ 0.08，不拒絕虛無假說；

判斷重點 | 錯誤：Z 值算錯；雖然不拒絕的方向正確。

C

Z $\approx$ 0.75，拒絕虛無假說；

判斷重點 | 錯誤：Z 值正確，但 0.75 未達 1.645，不能拒絕。

D

Z $\approx$ 0.75，不拒絕虛無假說

判斷重點 | 正確：正確；Z $\approx$ 0.75，證據不足以支持平均時間大於 36 分鐘。

原始題目

某生技公司正在進行新型 AI 輔助新藥篩選的臨床試驗，並將顯著水準由 $\alpha=0.05$ 降低至 $\alpha=0.01$ 。在新藥療效安全試驗的情境下，此調整對統計檢定的直接影響為何？

題目與選項標注

題目重點：把 α 從 0.05 降至 0.01，直接效果是降低把無效藥物誤判有效的型一錯誤機率。

判斷關鍵： α 本身就是容許的偽陽性風險上限。

A

降低型二錯誤 (Type II Error / β) 的發生機率，減少未能偵測到有效藥物的風險；

判斷重點 | 錯誤：降低 α 通常會使型二錯誤上升，而非下降。

B

降低型一錯誤 (Type I Error / α ，偽陽性) 的發生機率，減少將無效藥物誤判為有效 並進入後續高成本試驗的風險；

判斷重點 | 正確：正確；門檻更嚴格，偽陽性較少。

C

增加樣本數以提升統計功效 (Statistical Power)，進而改善估計精度；

判斷重點 | 錯誤：樣本數不會因調整 α 自動增加。

D

降低統計計算過程中的數值誤差，提高 p 值的精確度

判斷重點 | 錯誤： α 是決策門檻，不是數值計算精度。

原始題目

某團隊為職業籃球隊建立球員受傷風險預測模型，原始特徵 280 個。初始模型訓練集 AUC 為 0.94、測試集僅 0.68，顯示嚴重過擬合。為改善模型，團隊進行以下處理步驟：第一步於全體資料（含測試集）上計算特徵間線性相關係數並移除高度相關特徵；第二步依模型重要性篩選特徵後重新訓練模型。最終測試集 AUC 提升至 0.81。關於上述調整流程，下列敘述何者最為正確？

題目與選項標注

題目重點：任何使用標籤或整體分布決定特徵的步驟都應只在訓練資料內擬合；Pearson 相關只能衡量線性關係。

判斷關鍵：先切分，再在訓練集做篩選與轉換。

A

使用相關係數進行特徵篩選方向正確，主要問題在於相關係數門檻設定過高；

判斷重點 | 錯誤：主要問題不是門檻，而是測試集參與特徵選擇。

B

在全體資料（含測試集）上進行特徵篩選會造成資料洩漏，且線性相關無法捕捉非線性關係；

判斷重點 | 正確：正確；全資料篩選造成洩漏，線性相關也會漏掉非線性關係。

C

特徵篩選後需重新對測試集進行標準化，否則會影響模型表現；

判斷重點 | 錯誤：標準化也應由訓練集擬合，但不是本題流程的核心錯誤。

D

測試集表現提升代表過擬合已解決，流程可直接部署

判斷重點 | 錯誤：測試表現改善不能抵銷評估流程已遭污染。

原始題目

某團隊為電信公司建立用戶月租方案續約預測模型，資料集包含兩個類別特徵：「客服評價」共有 5 個等級（非常不滿意至非常滿意），具明確順序關係；「居住縣市」共有 22 個不同類別，類別之間無順序關係。團隊計劃分別以 LogisticRegression 與 XGBoost 訓練模型，並對上述特徵進行編碼。請問下列哪個編碼方案最適當？

題目與選項標注

題目重點：客服評價具順序，可做 Ordinal；縣市無順序，線性模型用 One-Hot，XGBoost 可用原生 categorical。

判斷關鍵：先判斷類別是否有自然順序，再考慮模型特性。

A

兩模型皆將「客服評價」與「居住縣市」進行 One-Hot Encoding，保留全部欄位並使用相同特徵矩陣訓練模型；

判斷重點 | 錯誤：評價全做 One-Hot 會丟掉自然順序；也不一定是兩模型最佳共用方式。

B

LogisticRegression 將「客服評價」做 OrdinalEncoding、「居住縣市」以歷史續約率進行編碼且於資料切分前計算；XGBoost 對兩個特徵皆採 Ordinal Encoding 處理；

判斷重點 | 錯誤：目標編碼若在切分前計算會洩漏，且縣市任意序數編碼不理想。

C

Logistic Regression 將「客服評價」做 Ordinal Encoding、「居住縣市」進行 One-Hot Encoding 並採 Drop First；XGBoost 將「客服評價」採 Ordinal Encoding，「居住縣市」以類別型態輸入並啟用 enable_categorical；

判斷重點 | 正確：正確；分別匹配類別性質與模型能力。

D

兩個模型均將「客服評價」以平均續約率進行編碼，「居住縣市」先做 One-Hot Encoding 再以 PCA 降維，並統一作為兩模型輸入特徵

判斷重點 | 錯誤：用目標均值編碼仍有洩漏風險，PCA 也不是處理名目類別的必要步驟。

原始題目

某資料工程師在建構 AI 訓練資料處理流程時，需要處理一個 50GB 的 CSV 檔案，其大小遠超過系統可用記憶體。他使用 Python 的 Pandas 進行資料前處理，但直接呼叫 `pd.read_csv()` 時出現記憶體溢位（`OutofMemory,OOM`）錯誤。在不改用其他分散式框架的前提下，下列哪個參數最能有效解決此問題？

題目與選項標注

題目重點：`chunksize` 讓 `read_csv` 回傳可逐批迭代的資料塊，避免一次把 50GB 載入記憶體。

判斷關鍵：題目要求仍用 Pandas 且處理完整資料。

A `nrows=10000`：限制僅讀取前 N 筆資料以避免記憶體溢位；

判斷重點 | 錯誤：只讀前 N 筆會遺失其餘資料。

B `usecols=0.5`：隨機載入 50% 的資料欄位，以減半記憶體使用量；

判斷重點 | 錯誤：`usecols` 需要指定欄位，不接受 0.5 代表隨機半數欄。

C `chunksize=10000`：分批讀取資料並逐批處理，避免一次載入整個檔案；

判斷重點 | 正確：正確；逐批讀取並處理可控制記憶體。

D `dtype`：指定欄位資料型別以降低記憶體使用量

判斷重點 | 錯誤：指定 `dtype` 可節省記憶體，但不一定足以容納 50GB。

原始題目

某電商平台正在重構商品資料架構，需同時支援三個系統：商品管理後台需處理結構化與半結構化資料（如巢狀庫存與不同類別商品欄位差異），並支援複雜條件查詢；AI 推薦系統需儲存高維向量（1,536 維）並進行高效相似度搜尋（高 QPS）；即時庫存服務則要求 ACID 且延遲低於 10ms，以避免超賣。在此情境下，哪種資料庫架構最適合？

題目與選項標注

題目重點：半結構商品適合文件庫、高維相似搜尋適合向量庫、強 ACID 庫存適合關聯式資料庫。

判斷關鍵：這是 polyglot persistence：不同需求使用不同儲存引擎。

A

全部使用關聯式資料庫，透過 JSON 欄位儲存巢狀資料，並以延伸套件支援向量搜尋，同時以資料列鎖（Row-level Lock）處理庫存扣減；

判斷重點 | 錯誤：單一關聯式方案可行但難同時把各類工作負載做到最佳。

B

商品資料使用文件型資料庫，向量搜尋使用專用向量資料庫，庫存服務使用關聯式資料庫，各系統依需求選擇最適合的資料庫；

判斷重點 | 正確：正確；各服務依資料型態、一致性與查詢模式選擇。

C

全部使用文件型資料庫，同時處理商品資料、向量搜尋與庫存服務，以統一技術棧降低維運複雜度；

判斷重點 | 錯誤：文件庫不擅長所有向量與強交易情境。

D

商品與向量資料使用搜尋引擎型資料庫，並以文件更新機制處理庫存扣減

判斷重點 | 錯誤：搜尋引擎不適合承擔庫存扣減的強一致交易。

原始題目

某 AI 平台的資料量已達 PB 級，單一資料庫節點已無法負荷，決定採用分片（Sharding）策略。下列何者為 Sharding 設計的主要目的？

題目與選項標注

題目重點：分片把資料依分片鍵水平分散到多個節點，以提升容量、吞吐與負載均衡。

判斷關鍵：Sharding 是切資料；Replication 是複製資料。

A

增加資料備份數量以提升安全性；

判斷重點 | 錯誤：增加備份是複寫，不是分片的主要目的。

B

將查詢結果預先計算以降低延遲；

判斷重點 | 錯誤：預先計算屬快取或物化檢視。

C

將資料水平分割以提升擴展性與負載均衡；

判斷重點 | 正確：正確；水平切分可突破單一節點上限。

D

將資料壓縮以減少儲存成本

判斷重點 | 錯誤：資料壓縮降低容量，但不是 Sharding。

原始題目

某資料工程師在建構大規模影像資料處理流程時，需要處理數千萬筆訓練影像，並發現模型出現嚴重的過度擬合（Overfitting）：訓練集準確率達 99%，但驗證集僅有 72%。在不改變模型架構的前提下，下列哪一項「資料處理層面」的調整最無法有效改善過度擬合，甚至可能使問題惡化？

題目與選項標注

題目重點：反覆使用同一批固定特徵只提升吞吐，沒有增加有效樣本多樣性，無法改善過擬合。

判斷關鍵：問「最無法改善」：找只加速、未改進資料品質或多樣性的作法。

A

在資料處理流程中加入資料增強（DataAugmentation），於訓練時動態生成多樣化影像樣本；

判斷重點 | 錯誤：動態資料增強可增加有效變化。

B

擴充資料來源，收集更多不同場景與條件的影像，以提升訓練資料分布的多樣性；

判斷重點 | 錯誤：增加不同場景資料能提升覆蓋與泛化。

C

為了提升資料處理吞吐量（Throughput），預先將影像轉為固定特徵並快取（Cache），反覆使用相同訓練資料以加速訓練流程；

判斷重點 | 正確：正確答案；固定快取資料反覆使用可能加深記憶訓練集。

D

在資料前處理階段進行資料清理，移除標註錯誤或品質不佳的影像資料

判斷重點 | 錯誤：清除錯標與劣質資料可改善學習訊號。

原始題目

某工程師在建立推薦系統時，評估使用奇異值分解（Singular Value Decomposition, SVD）對使用者-商品評分矩陣進行潛在語意分析（Latent Semantic Analysis, LSA）。關於 SVD 的數學性質，下列何者不正確？

題目與選項標注

題目重點：任意 $m \times n$ 矩陣都可做 SVD；截斷 SVD 常用於降維與 LSA。

判斷關鍵：題目問不正確，抓「只能方陣」。

A

SVD 只能分解方陣（Square Matrix），無法應用於行列數不相等的長方形矩陣；

判斷重點 | 正確：錯；SVD 可分解長方形矩陣，因此 A 為不正確敘述。

B

SVD 常用於降維（Dimensionality Reduction），透過保留最大的 k 個奇異值來近似原始矩陣（截斷 SVD）；

判斷重點 | 錯誤：保留最大奇異值可形成低秩近似。

C

SVD 比 PCA 更一般化，因為 PCA 可視為對資料的共變異數矩陣（Covariance Matrix）進行的特殊 SVD 運算；

判斷重點 | 錯誤：PCA 可由中心化資料的 SVD 求得。

D

LSA 是 SVD 在文字-文件矩陣上的應用，透過截斷 SVD 捕捉詞語與文件的潛在語意關係

判斷重點 | 錯誤：LSA 的確把 SVD 用在詞-文件矩陣。

原始題目

某醫院欲建立一套加護病房（ICU）敗血症預測模型，資料來自 120 位病患之生命徵象（如心率、血壓、體溫等），每 5 分鐘記錄一次。資料中敗血症相關樣本僅佔 3.2%，屬於高度不平衡資料。在資料檢查過程中發現數項問題，包括血氧資料會出現 10 至 30 分鐘的連續缺失、部分血壓感測器隨使用時間產生系統性偏高（感測器漂移）、敗血症標註時間存在約 ± 2 小時誤差，以及不同病患之正常生命徵象基準差異甚大。請問下列何種資料處理與建模方式最為適當？

題目與選項標注

題目重點：需同時處理連續缺失、感測器漂移、標註雜訊、病患個體差異與群組切分，並以適合不平衡的指標評估。

判斷關鍵：醫療時序最怕同一病患跨訓練 / 測試造成洩漏。

A

將缺失值以整體平均填補，未額外處理感測器漂移，並將敗血症標註區間由 6 小時擴大至 8 小時以涵蓋時間誤差，模型評估採用 ROC-AUC 作為主要指標；

判斷重點 | 錯誤：整體平均會抹平時序與個體差異，ROC-AUC 也可能掩蓋少數類。

B

對缺失值進行線性插值，若連續缺失時間過長則刪除該段資料，並以 Z-score 標準化處理感測器漂移，交叉驗證採隨機切分，未避免同一病患資料同時出現在訓練與測試集中；

判斷重點 | 錯誤：隨機切分會讓同一病患資料洩漏到測試集，Z-score 也未必能校正漂移。

C

刪除所有含缺失值之資料，對資料進行 Min-Max 正規化處理，未考慮病患間差異直接建模，並以 Accuracy 作為評估指標，交叉驗證採分層 K-Fold 方式進行；

判斷重點 | 錯誤：大量刪除缺失資料、忽略個體差異並只看 Accuracy 都不適當。

D

對缺失值採前向填補並加入缺失指標特徵，利用感測器 72 小時滾動中位數進行漂移校正，並處理標註雜訊，同時以個別病患基準建模，交叉驗證採病患分組，評估採 PR-AUC 與 Recall 指標

判斷重點 | 正確：正確；各資料問題均有對應處理，並採病患分組驗證與 PR-AUC / Recall。

原始題目

某零售企業的 AI 工程師正在用關聯規則學習（Association Rule Learning）分析購物籃資料，評估商品 A 跟商品 B 之間同時購買的關係。關於「支援度（Support）」、「信賴度（Confidence）」、「提升度（Lift）」三個指標，下列敘述何者正確？

題目與選項標注

題目重點：Support= $P(A \cap B)$ ，Confidence= $P(B|A)$ ，Lift= $P(A \cap B) / [P(A)P(B)]$ ；Lift=1 表示獨立。

判斷關鍵：先把三個公式一一配對。

A

信賴度= $P(A \cap B)$ ，即 A 與 B 同時出現的機率，範圍[0,1]；

判斷重點 | 錯誤：把 Confidence 誤寫成 Support。

B

支援度= $P(B|A)$ ，即 A 出現時 B 也出現的條件機率，範圍[0,1]；

判斷重點 | 錯誤：把 Support 誤寫成 Confidence。

C

提升度= $P(A \cap B) / [P(A) \times P(B)]$ ，範圍固定在[0,1]之間；

判斷重點 | 錯誤：Lift 公式對，但範圍不只 0 到 1。

D

提升度=1 表示 A 與 B 獨立（無關聯），<1 表示負相關，>1 表示正向關聯，因此提升度並非數值愈大即代表關聯愈強

判斷重點 | 正確：正確；Lift 的 1 是獨立基準，低於 / 高於 1 分別為負 / 正關聯。

原始題目

下圖表為電商平台某時段的交易紀錄（共 8 筆訂單），對圖表內的資料執行 Apriori 演算法，設定最低支援度為 3。請問最終保留下來的最大頻繁項目集為何？

訂單	商品集合
1	A, B, E
2	C, D
3	B, D, E
4	A, B, E
5	B, C, E
6	A, D
7	A
8	A, D

題目與選項標注

題目重點：最低支援計數為 3；{B,E} 出現於訂單 1、3、4、5 共 4 次，且沒有更大且達門檻的超集合。

判斷關鍵：先數每個候選集合出現次數，再找 maximal frequent itemset。

A {A}；

判斷重點 | 錯誤：{A} 雖頻繁，但不是最大集合。

B {A, D}；

判斷重點 | 錯誤：{A,D} 僅出現於訂單 6、8，共 2 次。

C {A, B, E}；

判斷重點 | 錯誤：{A,B,E} 僅出現於訂單 1、4，共 2 次。

D {B, E}

判斷重點 | 正確：正確；{B,E} 支援計數為 4，且為最大頻繁集合。

原始題目

某電信公司的 AI 反詐欺模型在正常交易佔 99.5%、詐欺交易僅佔 0.5% 的類別嚴重不平衡資料集上訓練。若工程師僅以整體準確率（Accuracy）作為模型選擇的唯一指標，最可能產生什麼嚴重問題？

題目與選項標注

題目重點：若永遠預測 99.5% 的正常類，Accuracy 仍達 99.5%，但詐欺 Recall 為 0。

判斷關鍵：先寫出多數類基準模型，再看少數類指標。

A

模型訓練時間會因類別不平衡而大幅增加；

判斷重點 | 錯誤：不平衡不會必然大幅增加訓練時間。

B

一個永遠預測為正常交易的模型即可達到 99.5% 準確率，但對詐欺交易的召回率為 0%，使準確率失去判別能力；

判斷重點 | 正確：正確；高 Accuracy 可能完全沒有偵測詐欺的能力。

C

類別不平衡會導致模型訓練過程出現梯度爆炸；

判斷重點 | 錯誤：不平衡本身不等於梯度爆炸。

D

類別不平衡會直接導致模型過擬合，使測試集表現下降

判斷重點 | 錯誤：它可能造成偏向多數類，但不會直接等同一般意義的過擬合。

原始題目

某 AI 平台的資料工程師需要在 Apache Spark 叢集上，對包含 10 億筆使用者行為紀錄的 RDD/DataFrame 計算整體標準差 (StandardDeviation)。請問下列哪種策略在分散式環境中最正確且有效率？

題目與選項標注

題目重點：標準差可用可合併的局部統計量在 Executor 計算，再聚合到全域結果。

判斷關鍵：避免把 10 億筆資料 collect 到 Driver。

A

呼叫 collect()將所有資料傳回 Driver 節點的本機記憶體後，再使用 Python 的 statistics.stdev()計算；

判斷重點 | 錯誤：collect 會造成 Driver 記憶體與網路瓶頸。

B

先對資料進行全域排序 (sortBy)，再取中間值計算變異數；

判斷重點 | 錯誤：標準差不需要全域排序。

C

將資料輸出為 CSV，再以 Excel 的 STDEV 函數計算；

判斷重點 | 錯誤：輸出 CSV 再用 Excel 無法處理這種規模。

D

使用 DataFrame.agg({'col': 'stddev'})或 RDD.aggregate()等分散式統計方法，由各 Executor 計算局部統計量後再進行彙總

判斷重點 | 正確：正確；agg / aggregate 讓計算留在叢集上分散完成。

原始題目

某連鎖便利商店集團欲建立門市未來 14 天每日銷售額預測模型（500 間門市、3 年歷史資料）。資料具有明顯的週期性（週末較高）、年度季節性（暑假與年末高峰）及長期成長趨勢，並包含已知節日與不定期事件（如颱風）。在此情境下，關於資料切分與建模策略，何者最適當？

題目與選項標注

題目重點：需保留時間順序，使用前進式驗證，並納入季節、滯後、滾動與事件特徵。

判斷關鍵：時間資料不可隨機打散，否則未來資訊會洩漏。

A

採隨機切分（80/20），使用傳統時間序列模型建模，刪除節日資料避免極端值影響，並以均方根誤差（RMSE）評估；

判斷重點 | 錯誤：隨機切分破壞時間順序，刪節日也會丟失重要訊號。

B

依時間順序切分（最後 90 天為測試集），使用具季節性建模能力的時間序列模型並加入節日資訊，不處理不定期事件，以平均絕對百分比誤差（MAPE）評估；

判斷重點 | 錯誤：方向較好，但忽略颱風等不定期事件且驗證不足。

C

依時間順序切分並採前進式驗證（Walk-Forward Validation），結合時間序列分解與機器學習模型，加入時間特徵、滯後與滾動統計特徵，並納入節日與不定期事件資訊，使用均方根誤差（RMSE）與平均絕對百分比誤差（MAPE）評估；

判斷重點 | 正確：正確；切分、驗證、特徵與評估都符合多門市預測。


D

依時間順序切分，直接使用深度學習模型建模，不進行特徵工程，所有門市共用模型，以平均絕對誤差（MAE）評估

判斷重點 | 錯誤：深度模型不代表可以省略特徵與門市差異。

原始題目

Receiver Operating Characteristic (ROC) 曲線係由單一分類模型在不同決策閾值下形成，並以真陽率 (True Positive Rate, TPR) 為縱軸、假陽率 (False Positive Rate, FPR) 為橫軸。請問下圖中四條曲線，何者最不可能是 ROC 曲線？



原公告試題中的 ROC 曲線圖

題目與選項標注

題目重點：隨閾值放寬，FPR 與 TPR 都不會下降，所以 ROC 從左下往右上必須單調。

判斷關鍵：曲線若往右走時 TPR 下跌，就不可能來自同一模型的閾值掃描。

A

水平線 A；

判斷重點 | 錯誤：水平線仍可單調不下降，雖模型特性特殊。

B

曲線 B；

判斷重點 | 錯誤：B 保持單調上升，可能是 ROC。

C

曲線 C；

判斷重點 | 正確：正確答案；C 中段明顯下降，違反 ROC 單調性。

D

斜直線 D

判斷重點 | 錯誤：隨機分類器的 ROC 可是對角線。

原始題目

某 AI 工程師評估客戶滿意度評分（1–5 分，含有明顯離群值）與退款率（連續型比例變數）之間的相關性，考慮使用皮爾森（Pearson）、斯皮爾曼（Spearman）或肯德爾（Kendall）相關係數。關於三者的特性比較，下列敘述何者不正確？

題目與選項標注

題目重點：Pearson 看線性；Spearman 與 Kendall 看排名 / 單調關係。Kendall 通常對小樣本、離群與大量 ties 更穩健。

判斷關鍵：題目問不正確，辨認 Spearman 與 Kendall 的穩健性比較。

A 皮爾森衡量兩個連續變數間的線性關係強度；斯皮爾曼與肯德爾基於排名（Rank）計算，對非線性單調關係也適用；
判斷重點 | 錯誤：三者的關係型態描述正確。

B 斯皮爾曼相關係數的計算公式等價於皮爾森，只是將原始數值替換為其排名後代入計算；
判斷重點 | 錯誤：Spearman 可視為對排名後資料計算 Pearson。

C 與肯德爾相比，斯皮爾曼對離群值的穩健度更強；
判斷重點 | 正確：不正確；不能概括說 Spearman 比 Kendall 更穩健。

D 三者的數值範圍（相關係數區間）皆相同，均在 $[-1, 1]$ 之間
判斷重點 | 錯誤：三者係數範圍均為 -1 到 1 。

原始題目

某金融機構導入 AI 模型進行信用卡詐欺偵測，由於詐欺交易極為稀少（約佔全部交易 0.3%），因此模型在測試階段得到 99.6% 準確率（Accuracy），被初步認定為「高效模型」。然而在實際上線後，風控部門發現模型幾乎無法攔截詐欺交易，且大量誤判正常交易。經進一步檢查，發現資料極度不平衡，但模型仍以 Accuracy 作為主要優化與評估指標。在此情境下，下列何者最適當的改善方向？

題目與選項標注

題目重點：Class Weight / Cost-sensitive Learning 直接提高少數類錯誤的損失權重，使模型重視詐欺。

判斷關鍵：準確率不是主目標；需要兼顧詐欺召回與誤報成本。

A

持續優化 Accuracy 指標以提升整體分類正確率；

判斷重點 | 錯誤：繼續只最佳化 Accuracy 會維持多數類偏誤。

B

改用精確率（Precision）作為主要評估指標以降低誤報；

判斷重點 | 錯誤：只看 Precision 可能仍漏掉大量詐欺。

C

引入 Class Weight 或 Cost-sensitive Learning 調整損失函數；

判斷重點 | 正確：正確；調整損失函數能反映少數類與業務成本。

D

移除少數類資料以提升模型穩定性與收斂速度

判斷重點 | 錯誤：移除少數類會讓模型更難學會詐欺。

原始題目

某電商推薦系統的資料工程師在建構模型特徵時，將使用者的訂單 UNIX 時間戳記（連續數值）轉換為「早晨（6—12 時）、下午（12—18 時）、夜晚（18—6 時）」三個區間類別，以讓推薦模型更容易學習消費時段規律。在資料前處理中，這種將連續數值轉換為有序類別的操作最精確的名稱為何？

題目與選項標注

題目重點：把時間戳的連續 / 數值資訊切成早晨、下午、夜晚區間，稱為 discretization / binning。

判斷關鍵：切區間是離散化；轉成虛擬欄位才是 One-Hot。

A

特徵離散化 (Feature Discretization) ；

判斷重點 | 正確：正確；將連續值分箱為類別。

B

特徵縮放 (Feature Scaling) ；

判斷重點 | 錯誤：縮放只改數值尺度，不會切成類別。

C

數據降維 (Dimensionality Reduction) ；

判斷重點 | 錯誤：降維減少特徵維數，不是分箱。

D

One-Hot 編碼 (One-Hot Encoding)

判斷重點 | 錯誤：One-Hot 是離散化後可再做的編碼步驟。

原始題目

某 AI 產品的商業分析師在準備月度報告時，需要在單一頁面上同時呈現 1,000 位使用者的留存率、活躍程度與付費轉換率三項指標，以讓決策層快速掌握整體趨勢。若依據 Edward Tufte 的資料視覺化原則中資料密度（Data Density）的概念，下列何者最符合此原則的設計方向？

題目與選項標注

題目重點：資料密度是在有限空間呈現高比例的有效資訊，同時維持清楚可讀。

判斷關鍵：不是單純塞滿，也不是把所有輔助資訊刪光。

A

將 1,000 筆資料分散至多張圖表（每張顯示約 100 筆），避免單一圖表資訊過載；

判斷重點 | 錯誤：分散圖表可能降低同頁比較效率，不符合高密度目標。

B

移除所有圖例、軸標籤與輔助線等非資料墨水（Non-data Ink），使版面最簡潔；

判斷重點 | 錯誤：移除全部標籤會損害可讀性；非資料墨水應減量而非歸零。

C

在圖表中加入大量裝飾性元素（如色塊、陰影、3D 效果），使視覺效果更豐富；

判斷重點 | 錯誤：裝飾性 3D、陰影增加 chartjunk。

D

在有限頁面空間中呈現盡可能多的有效資料資訊，同時維持可讀性與清楚的視覺層次

判斷重點 | 正確：正確；提高有效資料量並維持視覺層次。

原始題目

行銷團隊比較三種廣告投放管道（A / B / C）的轉換率差異，原始數據如下，A：3.2%、B：3.8%、C：4.0%。若設計圖表時將 y 軸刻意截斷（不從 0 開始），造成視覺差異放大。此做法最可能產生的問題為何？

題目與選項標注

題目重點：長條圖若 y 軸不從 0 開始，會放大 3.2% 到 4.0% 的相對視覺差距。

判斷關鍵：圖形的視覺比例應對應資料差異。

A

提升資料解析效率並減少認知負擔；

判斷重點 | 錯誤：截斷軸不會提升解析效率。

B

增強小幅差異的可視化辨識能力；

判斷重點 | 錯誤：雖更容易看出小差異，但會扭曲差異幅度，不能視為正當理由。

C

造成視覺誤導並放大實際差異感；

判斷重點 | 正確：正確；視覺效果誇大了實際差距。

D

提升圖表計算準確性與數據正確性

判斷重點 | 錯誤：軸的起點不會提升資料本身的計算準確性。

原始題目

某 AI 系統的維運工程師需要在儀表板上呈現「模型推論延遲 (ms) 隨時間的變化趨勢」，以便即時監控 服務水準協議 (ServiceLevelAgreement,SLA) 是否達標 (P99<200 ms)。在資料視覺化的圖表類型選擇上，下列哪種圖表最適合呈現連續數值隨時間變化 的趨勢？

題目與選項標注

題目重點：連續時間上的 P99 延遲最適用折線圖，並可加上 200ms SLA 參考線。

判斷關鍵：看到「隨時間的變化趨勢」優先想到折線圖。

A 面積圖 (Area Chart) ；

判斷重點 | 錯誤：面積圖較強調累積量或規模，不如折線圖直接。

B 散佈圖 (Scatter Plot) ；

判斷重點 | 錯誤：散佈圖可呈現關係，但不是連續趨勢的首選。

C 長條圖 (Bar Chart) ；

判斷重點 | 錯誤：長條圖適合離散類別比較。

D 折線圖 (Line Plot)

判斷重點 | 正確：正確；折線圖能清楚顯示延遲隨時間的連續變化。

原始題目

訓練資料共 5,000 萬筆，工程師比較 Batch Size=32 與 Batch Size = 4096 的訓練表現，發現大批次（LargeBatch）雖然訓練較快，但模型泛化能力較差。從最佳化理論角度，下列何者為此現象最合理的解釋？

題目與選項標注

題目重點：大批次梯度較平滑、雜訊少，可能收斂到較尖銳的極小值；小批次雜訊有時有助跳離並找到較平坦解。

判斷關鍵：訓練更快不等於泛化更好。

A

大批次（Large Batch）計算量過大，GPU 無法有效處理；

判斷重點 | 錯誤：大批次通常正是為了提高 GPU 吞吐，不是 GPU 無法處理。

B

大批次（LargeBatch）梯度估計更穩定，但容易收斂至局部極小值（LocalMinima），導致泛化能力較差；

判斷重點 | 正確：依公告答案，穩定梯度較易陷入不利泛化的極小值；更精確地說常與 sharp minima 有關。

C

小批次（Small Batch）因隨機性高，更容易發生梯度爆炸（Gradient Explosion）；

判斷重點 | 錯誤：小批次的隨機性不等於必然梯度爆炸。

D

批次大小（Batch Size）與泛化能力無關，問題出在學習率（Learning Rate）設定

判斷重點 | 錯誤：Batch Size 會影響梯度雜訊與泛化。

原始題目

某公司中，A 團隊負責信用評分模型，B 團隊負責詐欺偵測模型，兩團隊皆需要「使用者過去 30 天交易行為」資料，但各自會進行特徵工程與後續工作。以公司整體管理角度，下列何者為導入統一管理與共用特徵的主要目的？

題目與選項標注

題目重點：統一特徵管理可讓多團隊重用一致定義，降低重複開發、線上 / 離線不一致與維護成本。

判斷關鍵：題幹聚焦兩團隊重做相同 30 天行為特徵。

A

模型推論延遲過高，導致線上服務回應時間不符合系統即時性需求與使用體驗要求；

判斷重點 | 錯誤：推論延遲不是題幹指出的跨團隊問題。

B

降低跨團隊重複開發的維護成本；

判斷重點 | 正確：正確；共用特徵避免重工並提升一致性。

C

訓練資料儲存空間不足，造成歷史資料保存與批次訓練流程效率下降問題；

判斷重點 | 錯誤：儲存空間不是導入共用特徵的主要目的。

D

模型版本管理混亂，導致不同模型部署與回溯分析困難並增加維運複雜度

判斷重點 | 錯誤：模型版本管理應由 Model Registry 處理。

原始題目

某銀行建置貸款違約預測模型，資料共 50,000 筆，其中違約樣本僅 800 筆（佔 1.6%）。在模型建置流程中，先對整體資料使用 SMOTE 對少數類進行過採樣，之後再進行訓練 / 測試切分，並訓練輕量梯度提升機（LightGBM）模型，並以 AUC-ROC 評估模型表現。模型在測試集的 AUC-ROC 達到 0.91，團隊認為模型表現良好，準備上線部署。在模型審查過程中，下列何者為使測試集評估結果失真的主要原因？

題目與選項標注

題目重點：SMOTE 只能在訓練資料內擬合與產生合成樣本，否則相鄰資訊會滲入測試集。

判斷關鍵：先切分；交叉驗證時也只在每個 training fold 做 SMOTE。

A

SMOTE 不適合用於金融違約預測場景，此類高風險業務應一律採用 `class_weight` 調整損失函數，而非對資料本身進行過採樣；

判斷重點 | 錯誤：SMOTE 並非金融場景一律禁用。

B

SMOTE 的過採樣操作在訓練/測試切分之前即對全體資料執行，導致合成樣本資訊洩漏至測試集，使 AUC-ROC 0.91 虛高而不可信；

判斷重點 | 正確：正確；切分前過採樣污染測試集，使 AUC 虛高。

C

AUC-ROC 在 1.6% 的不平衡場景下過度樂觀，應改用 PR-AUC 作為評估指標，其餘流程均正確；

判斷重點 | 錯誤：PR-AUC 更有參考價值，但無法修復已發生的資料洩漏。

D

LightGBM 本身已內建處理不平衡的機制，與 SMOTE 同時使用會造成少數類過度補償，導致過多誤判

判斷重點 | 錯誤：與 LightGBM 並用需調整，但不是評估失真的主要原因。

原始題目

某線上書店希望建立一個多類別書籍推薦模型，根據讀者的「年齡、性別、過去購書類別偏好評分」等特徵，預測讀者下次最可能購買的書籍主題（共 8 類）。資料已完整標註，且資料量達數十萬筆。在模型選型上，除了預測準確率外，也需考量模型訓練效率、可擴充性，並需支援快速訓練與線上部署。請問下列哪種方法最適合此情境？

題目與選項標注

題目重點：有標註的 8 類分類、資料量大且要求快速訓練與部署，可用 Multinomial Logistic Regression 作為高效率基準。

判斷關鍵：分群與 PCA 都不是監督式分類器。

A

多類別羅吉斯迴歸（Multinomial Logistic Regression）；

判斷重點 | 正確：正確；原生支援多類別機率分類，訓練與部署效率高。

B

支援向量機（SVM）搭配 One-vs-One；

判斷重點 | 錯誤：One-vs-One SVM 在大量資料與多類別下訓練成本較高。

C

K-means 分群後將群集標籤作為分類結果；

判斷重點 | 錯誤：K-means 是無監督分群，不利用已標註類別。

D

主成分分析（PCA）後再以最大主成分作為分類依據

判斷重點 | 錯誤：PCA 是降維，不會直接輸出正確分類。

原始題目

某電商平台希望建立二元分類模型，根據商品的「價格區間、品牌、顏色、材質」等特徵，將商品分類為「高銷量 (1)」或「低銷量 (0)」 。同時希望模型輸出具備可解釋的 機率（如 $P=0.73$ 表示 73% 機率為高銷量） 。請問下列哪種方法最適合？

題目與選項標注

題目重點：Logistic Regression 以 sigmoid 將線性分數轉為 0~1 的類別機率。

判斷關鍵：題幹同時要求二元分類、機率與可解釋性。

A K-means 分群 (K-means Clustering) ；

判斷重點 | 錯誤：K-means 是分群，不直接學習高 / 低銷量標籤。

B 決策樹迴歸 (Decision Tree Regression) ；

判斷重點 | 錯誤：迴歸樹輸出連續值，不是標準的二元機率分類設定。

C 羅吉斯迴歸 (Logistic Regression) ；

判斷重點 | 正確：正確；可輸出 $P(y=1|x)$ 並解釋係數方向。

D 線性迴歸 (Linear Regression)

判斷重點 | 錯誤：線性迴歸輸出不受 0~1 限制，不適合直接當分類機率。

原始題目

某工程師在開發一個以 Transformer 為基礎的文本分類模型時，發現模型對於詞語順序 的變化不夠敏感，影響語意判斷效果。請問在 Transformer 架構中，位置編碼（Positional Encoding）的主要作用為何？

題目與選項標注

題目重點：Self-Attention 本身對排列不敏感，Positional Encoding 把位置訊息加入詞向量，使模型辨識詞序。

判斷關鍵：位置編碼解決的是順序，不是遮罩、隨機擾動或平行化本身。

A

在詞嵌入（Embedding）中加入隨機擾動，以提升模型對輸入變化的泛化能力；

判斷重點 | 錯誤：隨機擾動是正則化概念，不是位置編碼。

B

在注意力機制中加入遮罩（Mask），限制模型只能關注部分詞語；

判斷重點 | 錯誤：Mask 控制可見範圍，不能提供每個 token 的位置。

C

將輸入序列轉換為可同時運算的向量表示，以提升計算效率；

判斷重點 | 錯誤：平行運算是 Transformer 優勢，但不是位置編碼的主要作用。

D

在詞的向量表示中加入位置資訊，使模型能區分序列中不同位置的詞語

判斷重點 | 正確：正確；把序列位置注入表示。

原始題目

某 AI 系統架構師正在為一個電子商務資料湖（DataLake）設計系統。該資料湖儲存數百億筆使用者點擊紀錄，並作為企業主要的分析資料來源。系統需讓非技術背景的行銷人員能以自然語言查詢數據洞察（如：上個月台北市購買 3C 產品的女性轉換率為何？），同時滿足高精確性、可擴展性，支援資料庫層級的權限控管與查詢審計，並確保查詢結果可由資料庫引擎精確執行。在此情境下，下列何者為最適合的系統架構？

題目與選項標注

題目重點：LLM 把自然語言轉成 SQL，再由具權限與審計的資料庫引擎執行，可兼顧查詢彈性與精確聚合。

判斷關鍵：需要「精確執行＋權限＋審計」，核心是讓 DB 執行 SQL。

A

協同過濾（Collaborative Filtering）：根據歷史查詢推薦相似問題的答案，無法執行新問題的即時計算；

判斷重點 | 錯誤：協同過濾只能推薦相似查詢，不能執行新聚合。

B

檢索增強生成（RAG）：讓 LLM 檢索相關資料後生成回答，但無法可靠執行大規模數值聚合與精確統計查詢；

判斷重點 | 錯誤：RAG 擅長文件檢索，不保證正確完成大規模數值聚合。

C

生成對抗網路（GAN）：用於生成合成資料或模擬數據分佈，可用於資料擴增，但不適合即時查詢與資料庫聚合運算；

判斷重點 | 錯誤：GAN 用於資料生成，不是自然語言查詢介面。

D

Text-to-SQL Agent：由 LLM 將自然語言轉換為 SQL 查詢，交由分散式資料庫執行，兼顧自然語言彈性與資料查詢精確性

判斷重點 | 正確：正確；Text-to-SQL 由資料庫負責精確計算與治理。

原始題目

某金融機構將訓練好的信用評分模型開放 API 供合作夥伴查詢。資安團隊警告此設計 可能遭受成員推斷攻擊（MembershipInferenceAttack）。下列何者最準確說明攻擊原理 與對應防禦？

題目與選項標注

題目重點：模型常對訓練樣本輸出較高信心，攻擊者可據此推測某筆資料是否參與訓練。

判斷關鍵：不要和屬性推斷、模型竊取混淆。

A

利用模型對訓練樣本的高信心輸出判斷其是否屬於訓練集；以差分隱私或降低輸出 信心防禦；

判斷重點 | 正確：正確；差分隱私、正則化與限制輸出信心可降低風險。

B

利用查詢次數與回應頻率差異判斷資料是否在訓練集中；以限制查詢次數防禦；

判斷重點 | 錯誤：查詢頻率不是成員推斷的核心訊號。

C

透過模型輸出推測輸入的敏感特徵；以限制輸出資訊防禦；

判斷重點 | 錯誤：推測敏感特徵屬屬性推斷攻擊。

D

透過大量查詢建立替代模型模擬目標模型；以限制模型存取防禦

判斷重點 | 錯誤：建立替代模型屬模型萃取 / 竊取。

原始題目

某 AI 平台的資料治理工程師正在評估三種去識別化技術的適用場景與強度：K 匿名（K-anonymity）、差分隱私合成資料（Differential Privacy Synthetic Data）、亂數回應機制（Randomized Response）。下列敘述何者不正確？

題目與選項標注

題目重點：DP 合成資料通常是以差分隱私機制訓練生成器或估計分布，再發布合成樣本；不是直接對每筆原始資料加噪就稱合成資料。

判斷關鍵：題目問不正確，注意「差分隱私合成資料」與一般 DP 查詢機制的差別。

A

K 匿名主要應用於表格型資料，確保每筆記錄在準識別符（Quasi-identifier）組合上至少與 K-1 筆其他記錄相同，防止個體被唯一識別；

判斷重點 | 錯誤：K 匿名的定義正確。

B

差分隱私合成資料是在發布統計查詢結果或訓練模型時直接對原始資料加入雜訊，以確保單一個體的加入或移除不會顯著改變輸出；

判斷重點 | 正確：不正確；此敘述把 DP 合成資料混同於對原始資料 / 查詢直接加噪。

C

亂數回應機制讓受訪者以機率性方式回答敏感問題（如：您是否曾逃稅？），賦予個人對答案的可否認性（Plausible Deniability）；

判斷重點 | 錯誤：亂數回應以機率性回答提供可否認性。

D

三種技術中，只有差分隱私提供可組合且可量化的隱私保證，而 K 匿名與亂數回應在面對背景知識攻擊或多次查詢時保護能力有限

判斷重點 | 錯誤：差分隱私具有 ϵ 等可量化且可組合的保證。

原始題目

在建構自動化資料清洗管線時，工程師撰寫一個用於補齊缺失欄位的 Python 函式，如下圖所示。當此函式連續處理兩筆獨立的資料（row1 與 row2）後，請問第二筆資料 row2['tags'] 的內容會為何？

```
def process_record(record, tags=[]):  
    tags.append("checked")  
    record['tags'] = tags  
    return record
```

```
row1 = process_record({"id": 1})  
row2 = process_record({"id": 2})
```

題目與選項標注

題目重點：預設串列 tags=[] 只在函式定義時建立一次；兩次呼叫共用同一串列，所以第二次得到兩個 checked。

判斷關鍵：可變物件不應直接當預設值；改用 tags=None 再於函式內建立。

A

["checked", "tags"]；

判斷重點 | 錯誤：結果不會自動加入字串 tags。

B

[]；

判斷重點 | 錯誤：串列不會在每次呼叫時自動清空。

C

["checked", "checked"]；

判斷重點 | 正確：正確；第二次 append 後共享串列為 ["checked", "checked"]。

D

拋出 KeyError 錯誤，因為字典中沒有 tags 鍵值

判斷重點 | 錯誤：程式在賦值 record["tags"] 時會建立鍵，不會拋 KeyError。

原始題目

下圖為一段分類演算法的 pseudocode，請問最可能對應下列哪一種演算法？

Input:

- train_data: 訓練資料集，每筆包含特徵和標籤
- test_point: 要預測的新樣本
- x: 要考慮的最近鄰個數

Output:

- 預測的分類標籤

Algorithm:

1. 初始化一個空列表 distances
2. 對於每個訓練資料中的樣本 sample:
 - a. 計算 sample 與 test_point 的距離 distance
 - b. 把 (distance, sample 的標籤) 加到 distances 中
3. 按照距離對 distances 升序排序
4. 取出前 x 個距離最小的項目，記錄它們的標籤
5. 統計這 x 個標籤中出現次數最多的那個標籤
6. 返回該標籤作為 test_point 的預測結果

題目與選項標注

題目重點：對測試點計算到所有訓練樣本的距離，取最近 X 個並以多數標籤投票，就是 KNN。

判斷關鍵：看見「距離排序 + 最近鄰 + 投票」即可判斷。

A

K-近鄰 (K-Nearest Neighbors, KNN) ；

判斷重點 | 正確：正確；完全符合 K-Nearest Neighbors。

B

K-means 分群 (K-means Clustering) ；

判斷重點 | 錯誤：K-means 會反覆更新群中心，不使用標籤多數決。

C

支援向量機 (Support Vector Machine, SVM) ；

判斷重點 | 錯誤：SVM 尋找最大間隔決策邊界。

D

隨機森林分類器 (Random Forest Classifier)

判斷重點 | 錯誤：Random Forest 由多棵決策樹投票。

共用題組情境

某全球共享乘車平台的資料科學團隊，正針對 2025 年第四季度進行營收優化與防弊分析專案。團隊希望透過資料分析達成兩項目標：一是預測司機未來收入表現，以支援營運策略與獎勵機制調整；二是希望透過分析裝置與定位回傳資料，辨識潛在異常行為，以降低補貼濫用風險。

為此，團隊整理出一份司機每日營運資料檔（driver_daily_stats.csv），其中每筆資料代表某位司機於某一天的營運表現與系統回傳摘要資訊。資料欄位如下：

- driver_id：司機編號
- daily_earnings：日總收入（單位：美元）
- region：註冊營運區域（以字串 A、B、C 表示）
- app_version：使用的司機端 App 版本（如 v1.0、v2.0）
- gps_ping_rate：每分鐘回傳 GPS 訊號的次數

請根據此資料情境回答第 41~44 題。

原始題目

資料分析師使用Python檢視daily_earnings欄位的基本統計量，執行以下程式碼（Pandas 2 以上版本）：輸出結果如下：● mean：223.411306 ● 50%：128.552462 ● max：4500.000000 若團隊進一步發現 daily_earnings 欄位約有 5%的遺失值，且目前規劃先建立線性迴歸（LinearRegression）模型來預測未來收入。為盡可能保留該欄位原有分布特性，並降低因補值造成的偏差，請問下列哪一種處理方式最為合理？

```
import pandas as pd

df = pd.read_csv('driver_daily_stats.csv')
print(df['daily_earnings'].describe()[['mean', '50%', 'max']])

mean: 223.411306
50%: 128.552462
max: 4500.000000
```

題目與選項標注

題目重點：平均 223、中央值 128、最大 4500 顯示明顯右偏與極端值；中位數較不受離群值影響。

判斷關鍵：平均數遠高於中位數＝右偏；補值優先用 median。

A

df['daily_earnings'].fillna(df['daily_earnings'].mean(), inplace=True)；

判斷重點 | 錯誤：平均數被高收入離群值拉高，補值偏差較大。

B

df['daily_earnings'].fillna(df['daily_earnings'].median(), inplace=True)；

判斷重點 | 正確：正確；中位數較能保留右偏資料的典型中心。

C

df['daily_earnings'].fillna(df['daily_earnings'].max(), inplace=True)；

判斷重點 | 錯誤：最大值補值會嚴重扭曲分布。

D

直接刪除所有遺失資料，因數值型欄位不適合進行補值處理

判斷重點 | 錯誤：5% 遺失不必全部刪除，刪除會損失資訊且可能引入偏差。

原始題目

承上題，團隊在建立預測模型前，先將 region（A、B、C 區）轉換為整數 1、2、3，即採用標籤編碼（Label Encoding）。模型上線測試後發現，線性迴歸模型對於 C 區（編碼為 3）的預測收入出現明顯高估，顯示模型可能將編碼值誤解為具有線性大小關係。若主管要求不得修改原有的特徵編碼方式，必須維持 1、2、3 的整數表示，但希望從演算法層面降低此類誤解風險，則下列何者最適合作為替代模型？

題目與選項標注

題目重點：隨機森林用分裂規則處理數值碼，不會像線性模型把 1、2、3 強制解讀成等距線性效果。

判斷關鍵：題目限制不能改編碼，所以改用非線性的樹模型。

A

羅吉斯迴歸（Logistic Regression）；

判斷重點 | 錯誤：Logistic Regression 仍是線性決策形式，且本題目標是收入回歸。

B

Ridge 迴歸（Ridge Regression）；

判斷重點 | 錯誤：Ridge 仍保留線性大小關係。

C

支援向量機（Support Vector Machine, SVM）搭配線性核函數；

判斷重點 | 錯誤：線性核 SVM 同樣依賴線性距離結構。

D

隨機森林（Random Forest）

判斷重點 | 正確：正確；隨機森林可透過多次切分表達非線性區域差異。

原始題目

平台安全部門發現，僅有極少數司機（約占總體 0.05%）會利用外掛程式竄改 gps_ping_rate，以騙取里程補貼。某新進資料科學家訓練了一個二元分類模型，並在報告中指出：「模型整體準確率（Accuracy）高達 99.95%，因此可直接上線攔截可疑帳號。」然而，資深工程師檢視後認為，僅憑上述結果（如圖）仍不足以支持模型直接上線。下列何者不是其提出質疑的合理理由？

	precision	recall	f1-score
0	1.00	1.00	1.00
1	1.00	1.00	1.00
accuracy			1.00
macro avg	1.00	1.00	1.00
weighted avg	1.00	1.00	1.00

題目與選項標注

題目重點：異常偵測可用監督式分類、半監督或無監督方法；若有可靠標籤，分類模型並非不可用。

判斷關鍵：題目問「不是合理理由」，找絕對化的錯誤敘述。

A

在此類極度不平衡的資料中，即使模型永遠預測所有司機皆為正常，整體準確率仍可能高達 99.95%；

判斷重點 | 錯誤：全預測正常就可能得到 99.95%，質疑合理。

B

報告中未呈現召回率（Recall），因此模型可能無法有效辨識真正的外掛司機；

判斷重點 | 錯誤：缺少 Recall 無法知道抓到多少作弊者，質疑合理。

C

異常偵測問題不可使用分類模型處理，僅能使用分群或離群值方法；

判斷重點 | 正確：正確答案；異常偵測不是只能用分群或離群方法。

D

對於少數類比例極低的問題，若僅觀察 Accuracy，可能忽略模型對異常樣本的實際偵測能力

判斷重點 | 錯誤：只看 Accuracy 會忽略少數類能力，質疑合理。

原始題目

針對上述外掛偵測模型，營運長下達最終的商業決策目標如下：「對於作弊行為零容忍。即使誤凍結部分正常司機帳號，後續仍可交由人工覆核；但不能放過任何一個真正的外掛司機。」根據上述目標，團隊在調整模型輸出的決策機率門檻（Threshold，預設為 0.5）時，應採取下列何種策略最為合理？

題目與選項標注

題目重點：商業目標是盡量不漏掉作弊者，即降低 FN、提高 Recall；通常要降低決策門檻。

判斷關鍵：容許人工覆核誤報，代表可犧牲 Precision 換 Recall。

A

選擇使模型對作弊者的召回率（Recall）最大化的門檻，通常代表應降低 Threshold

判斷重點 | 正確：正確；降低門檻通常抓到更多正類，Recall 上升。

B

選擇使模型精確率（Precision）最大化的門檻，通常代表應提高 Threshold

判斷重點 | 錯誤：提高 Precision 常會漏掉更多作弊者，不符零漏抓。

C

固定使用 Threshold=0.5 作為預設值，因為調整門檻將破壞演算法原有的訓練平衡

判斷重點 | 錯誤：0.5 不是不可變的最佳門檻。

D

選擇使模型特異度（Specificity）達到 100% 的門檻，以確保正常司機不會被誤判

判斷重點 | 錯誤：Specificity=100% 強調不誤判正常者，與題目優先級相反。

共用題組情境

請依照以下情境回答第 45~47 題。

資料分析師載入一份電商交易紀錄的 Pandas DataFrame df，其欄位包含：OrderID（訂單編號）、CustomerID（客戶編號）、Category（商品分類）、Revenue（該筆營收）。此外，另有一份客戶資料表 customers，包含 CustomerID（客戶編號）與 Region（所在地區）欄位。

原始題目

若分析師想找出「總貢獻營收最高的前 3 名客戶」，下列 Pandas 程式碼何者最為精確 且 高效？

題目與選項標注

題目重點：每位客戶可能有多筆訂單，先 groupby CustomerID 後 sum Revenue，再 nlargest(3)。

判斷關鍵：題目要總貢獻，不是單筆最高或交易次數。

A

```
df.sort_values('Revenue', ascending=False).head(3)['CustomerID'];
```

判斷重點 | 錯誤：只會取營收最高的三筆訂單，可能重複同一客戶。

B

```
df.groupby('CustomerID')['Revenue'].max().head(3);
```

判斷重點 | 錯誤：max 只取每位客戶最大單筆，且 head 未排序。

C

```
df.groupby('CustomerID')['Revenue'].sum().nlargest(3);
```

判斷重點 | 正確：正確；先聚合總營收再取前三。

D

```
df.value_counts('CustomerID').head(3)
```

判斷重點 | 錯誤：value_counts 算的是訂單筆數，不是營收。

原始題目

若分析師只想計算「Electronics（電子產品）」這個特定分類的平均營收，下列何者為最佳的語法？

題目與選項標注

題目重點：df[df["Category"]=="Electronics"]["Revenue"].mean() 先用布林遮罩選列，再取欄位平均。

判斷關鍵：條件要寫在 Series 比較式裡。

A

```
df[df['Category'] == 'Electronics']['Revenue'].mean();
```

判斷重點 | 正確：正確；布林篩選與欄位平均語法完整。

B

```
df['Category'] == 'Electronics']['Revenue'].mean();
```

判斷重點 | 錯誤："Category"=="Electronics" 會先算成 False，不是欄位比較。

C

```
df.loc['Electronics', 'Revenue'].mean();
```

判斷重點 | 錯誤：loc 的第一個位置是索引標籤，不會自動以 Category 值選列。

D

```
df.filter(items=['Electronics'])['Revenue'].mean();
```

判斷重點 | 錯誤：filter(items=...) 是依欄名篩選，不是依欄位值篩選。

原始題目

分析師想將 customers 表中的 Region 欄位加入到 df 交易紀錄中，且「只保留那些在 customers 表中有對應資料的交易紀錄」。下列哪一種合併方式最正確？

題目與選項標注

題目重點：以 CustomerID 做 inner merge，會只留下兩表鍵值交集，並帶入 Region。

判斷關鍵：題幹直接描述 inner join 的語意。

A

`pd.concat([df, customers], axis=1) ;`

判斷重點 | 錯誤：concat(axis=1) 依索引橫向拼接，不保證 CustomerID 對齊。

B

`pd.merge(df, customers, on='CustomerID', how='outer') ;`

判斷重點 | 錯誤：outer 會保留無對應的兩側資料。

C

`pd.merge(df, customers, on='CustomerID', how='inner') ;`

判斷重點 | 正確：正確；inner 只保留 customers 中有對應的交易。

D

`df.join(customers, on='CustomerID')`

判斷重點 | 錯誤：join 預設依索引且為 left join，與題意不同。

共用題組情境

請根據下方資訊回答第 48~50 題。

使用鳶尾花卉資料集 (iris) 進行羅吉斯迴歸 (Logistic Regression) 分析，以下程式碼展示資料載入與處理。

原始題目

在進行機器學習建模前，資料分析師需對特徵變數 X 進行標準化處理，以消除不同量尺所造成的影響。已知使用 StandardScaler 進行資料轉換，程式碼如下：scaler = StandardScaler()。請問下列哪一種寫法可以正確完成資料標準化？

```
from sklearn.datasets import load_iris
from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import confusion_matrix, f1_score, classification_report

iris = load_iris()
X, y = iris.data, iris.target
feature_names = iris.feature_names
target_names = iris.target_names

print(X[0:5])
[[5.1 3.5 1.4 0.2]
 [4.9 3.  1.4 0.2]
 [4.7 3.2 1.3 0.2]
 [4.6 3.1 1.5 0.2]
 [5.  3.6 1.4 0.2]]
print(y[0:5])
[0 0 0 0 0]
print(feature_names)
['sepal length (cm)', 'sepal width (cm)', 'petal length (cm)', 'petal width (cm)']
print(target_names)
['setosa' 'versicolor' 'virginica']
```

題目與選項標注

題目重點：fit_transform(X) 先從 X 學習平均與標準差，再立即轉換 X。

判斷關鍵：fit 只學參數；transform 才套用。

A

X_norm = scaler.transform(X) ;

判斷重點 | 錯誤：尚未 fit 的 scaler 直接 transform 會出現 NotFittedError。

B

X_norm = scaler.fit(X) ;

判斷重點 | 錯誤：fit 回傳 scaler 本身，不是轉換後資料。

C

X_norm = scaler.fit_transform(X) ;

判斷重點 | 正確：正確；一次完成擬合與標準化。

D

X_norm = fit_transform(scaler)

判斷重點 | 錯誤：fit_transform 是 scaler 的方法，不是這種獨立函式呼叫。

原始題目

在進行機器學習建模前，資料分析師已完成資料前處理（包含遺漏值處理與特徵標準化），並準備建立分類模型。已知資料流程如下：1. 將資料區分為訓練集與測試集 2. 建立羅吉斯迴歸（Logistic Regression）模型 3. 使用訓練資料進行模型擬合（fit）請問下列哪一組 Pandas / Scikit-learn 程式碼流程最為正確？

題目與選項標注

題目重點：train_test_split 的前兩個輸入應是 X_norm、y；Iris 是多類別，lbfgs 可直接處理 multinomial。

判斷關鍵：先檢查 X/y 順序，再看 solver 是否適合多類別。

A `X_train, X_test, y_train, y_test = train_test_split(X_norm, y, train_size=0.2, random_state=123)`
`+log_reg = LogisticRegression(solver="liblinear")`
`+log_reg.fit(X_train, y_train)`

判斷重點 | 錯誤：X/y 順序正確，但 liblinear 不支援 multinomial，多類別通常採 one-vs-rest。

B `X_train, X_test, y_train, y_test = train_test_split(X_norm, y, train_size=0.2, random_state=123)`
`+log_reg = LogisticRegression(solver="lbfgs")`
`+log_reg.fit(X_train, y_train)`

判斷重點 | 正確：正確；X、y 順序正確，lbfgs 適合多類別羅吉斯迴歸。

C `X_train, X_test, y_train, y_test = train_test_split(y, X_norm, train_size=0.2, random_state=123)`
`+log_reg = LogisticRegression(solver="liblinear")`
`+log_reg.fit(X_train, y_train)`

判斷重點 | 錯誤：把 y 當特徵、X 當標籤，輸入順序錯誤。

D `X_train, X_test, y_train, y_test = train_test_split(y, X_norm, train_size=0.2, random_state=123)`
`+log_reg = LogisticRegression(solver="lbfgs")`
`+log_reg.fit(X_train, y_train)`

判斷重點 | 錯誤：同樣把 y 與 X_norm 的位置顛倒。

原始題目

參考下圖程式碼，下列描述何者正確？

```
y_pred = log_reg.predict(X_test)
cm = confusion_matrix(y_test, y_pred)
f1 = f1_score(y_test, y_pred, average="weighted")
print(cm)
[[13 0 0]
 [ 0 6 0]
 [ 0 0 10]]
print("F1-score (Weighted):", f1)
F1-score (Weighted): 0.9671550671550672
print(classification_report(y_test, y_pred, target_names=target_names))
```

題目與選項標注

題目重點：每類 F1 是 Precision 與 Recall 的調和平均；average="weighted" 再依各類 support 加權。

判斷關鍵：weighted 不是單純平均，而是按類別樣本數加權。

A

cm 表示混淆矩陣，橫列表測試集的預測值；

判斷重點 | 錯誤：sklearn confusion_matrix 的列通常是真實類別、欄才是預測類別。

B

混淆矩陣對角線數值皆大於非對角線數值表示模型過度擬合；

判斷重點 | 錯誤：對角線較大只表示分類較多正確，不能據此判定過擬合。

C

f1_score 參數 average="weighted" 表示計算平均 f1_score；

判斷重點 | 錯誤：weighted 不是未加權平均；未加權類別平均是 macro。

D

f1_score 計算時採用各類別精確率（Precision）與召回率（Recall）的調和平均，並加權考量類別不平衡性

判斷重點 | 正確：正確；先算各類 F1，再依 support 加權，適合考量類別比例。

試題與答案來源：115 年第一次 AI 應用規劃師中級能力鑑定公告試題，第二科：大數據處理分析與應用。

觀念依據：《AI 應用規劃師（中級）學習指引－科目 2 大數據處理分析與應用》。本頁為依官方資料製作的學習整理，並非官方解析。